

学校编码: 10384

学 号: 30920211154163

厦門大學

硕 士 学 位 论 文

基于三维视觉的室外场景重建研究

Research on Outdoor Scene Reconstruction Based on 3D
Vision

牛姝雯

指导教师姓名: 宋亮助理教授

专 业 名 称: 软件工程

论文提交日期: 2024 年 4 月

论文答辩日期: 2024 年 5 月

学位授予日期: 2024 年 6 月

2024 年 6 月

厦门大学学位论文原创性声明

本人呈交的学位论文是本人在导师指导下,独立完成的研究成果。本人在论文写作中参考其他个人或集体已经发表的研究成果,均在文中以适当方式明确标明,并符合法律规范和《厦门大学研究生学术活动规范(试行)》。

另外,该学位论文为()课题(组)的研究成果,获得()课题(组)经费或实验室的资助,在()实验室完成。(请在以上括号内填写课题或课题组负责人或实验室名称,未有此项声明内容的,可以不作特别声明。)

本人声明该学位论文不存在剽窃、抄袭等学术不端行为,并愿意承担因学术不端行为所带来的一切后果和法律责任。

声明人 (签名):

指导教师(签名):

年 月 日

厦门大学学位论文著作权使用声明

本人同意厦门大学根据《中华人民共和国学位条例暂行实施办法》等规定保留和使用此学位论文，并向主管部门或其指定机构送交学位论文（包括纸质版和电子版），允许学位论文进入厦门大学图书馆及其数据库被查阅、借阅。本人同意厦门大学将学位论文加入全国博士、硕士学位论文共建单位数据库进行检索，将学位论文的标题和摘要汇编出版，采用影印、缩印或者其它方式合理复制学位论文。

本学位论文属于：

（ ） 1. 经厦门大学保密委员会审查核定的涉密学位论文，
于 年 月 日解密，解密后适用上述授权。

（ ） 2. 不涉密，适用上述授权。

（请在以上相应括号内打“√”或填上相应内容。涉密学位论文应是已经厦门大学保密委员会审定过的学位论文，未经厦门大学保密委员会审定的学位论文均为公开学位论文。此声明栏不填写的，默认为公开学位论文，均适用上述授权。）

声明人（签名）：

年 月 日

摘 要

室外场景重建作为三维重建领域的热点课题，对于数字城市、无人驾驶和游戏开发等应用具有重要意义。目前，基于三维视觉的多视图重建技术因其低成本和操作简单等特点受到研究者的广泛关注。然而，该技术在应对室外场景重建任务时，常常受到室外场景中复杂的反射效应和动态非刚体对象的干扰，导致重建结果不佳。针对此难题，本文从图像分割和神经辐射场两个角度出发，为室外场景重建任务提供了有效的解决方案，主要工作如下：

本文将深度学习驱动的图像分割算法融入传统的多视图重建框架中，有效地减少了室外场景中的反射和动态非刚体对象造成的噪声干扰，从而显著提升了重建精度。针对室外场景中普遍存在的反射现象，本文提出基于多视图一致性的反射分割算法，借助其优越的反射分割性能，成功解决了传统重建方法在反射场景中失效的难题。此外，本文提出基于姿态估计的人体分割算法，利用人体姿态信息实现高精度的人体分割，从而消除人类活动对室外场景重建带来的干扰。

本文将神经辐射场技术引入室外场景重建任务中，分别对漫反射场景和反射场景提出有效的优化方案。针对漫反射场景，本文提出基于多视图立体的漫反射场景重建算法，有效地解决了神经辐射场的几何辐射歧义性问题，实现了更精准的几何重建。针对反射场景，本文提出分块解耦的优化算法，将反射纹理与透射场景成功分离，提升了神经辐射场对复杂反射的建模能力。

关键词： 三维重建；神经辐射场；图像分割；深度学习

Abstract

Outdoor scene reconstruction, as a hot topic in 3D reconstruction, is of significant importance for applications such as digital cities, autonomous driving, and game development. Currently, 3D vision-based reconstruction techniques have attracted significant interest from researchers due to their low cost and simplicity. However, when faced with outdoor scene reconstruction tasks, these methods often struggle with complexities arising from intricate reflection effects and the presence of dynamic non-rigid objects, leading to sub-optimal reconstruction outcomes. To address this challenge, this paper proposes effective solutions from two perspectives: image segmentation and neural radiance fields, with the main contributions summarized as follows:

This paper integrates deep learning-driven image segmentation algorithms into the traditional multi-view reconstruction framework, which effectively eliminates noise interference from reflections and dynamic non-rigid objects in outdoor scenes, thereby significantly improving reconstruction precision. To address the common challenge of reflections in outdoor scenes, this paper proposes a reflection segmentation algorithm based on multi-view consistency, leveraging its superior segmentation capabilities to effectively mitigate the inadequacy of traditional reconstruction methods under reflective scenarios. Additionally, this paper proposes a human segmentation algorithm based on pose estimation, which utilizes human pose information to achieve high-precision human segmentation, thereby eliminating the interference of human activities on outdoor scene reconstruction.

This paper applies neural radiance fields to the task of outdoor scene reconstruction, proposing effective optimization solutions for both diffuse and reflective scenes. For the diffuse scenes, this paper proposes a diffuse scene reconstruction algorithm based on multi-view stereo, effectively resolving the geometric-radiance ambiguity inherent in neural radiance fields and achieving more accurate geometric reconstruction. For the reflective scenes, we present a patch-wise decoupling optimization algorithm that successfully separates reflective textures from the transmitted scene, enhancing the neural radiance

fields' capability in modeling complex reflections.

Keywords: 3D Reconstruction; Neural Radiance Fields; Image Segmentation;
Deep Learning

目 录

摘 要	I
Abstract	II
目 录	IV
Contents	VII
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.2.1 反射识别与分割	3
1.2.2 非刚体检测与分割	4
1.2.3 基于隐式表示的三维重建	6
1.3 主要研究内容	7
1.4 论文组织结构	8
第 2 章 相关理论和技术	10
2.1 引言	10
2.2 计算机视觉中的注意力机制	10
2.2.1 Vision Transformer	12
2.2.2 Swin Transformer	14
2.3 多视图立体几何	15
2.3.1 相机模型	15
2.3.2 对极几何	18
2.3.3 三角化	19
2.3.4 运动恢复结构	19
2.4 基于神经辐射场的三维重建	21

2.4.1 体渲染	22
2.4.2 位置编码和分层采样	23
第 3 章 室外场景重建中的图像分割	23
3.1 引言	25
3.2 算法框架	26
3.3 基于多视图一致性的反射分割	27
3.3.1 网络整体设计	28
3.3.2 多视图一致性	29
3.3.3 损失函数	30
3.4 基于姿态估计的人体分割	31
3.4.1 多人姿态估计	31
3.4.2 网络整体设计	32
3.4.3 可移位交叉注意力模块	34
3.5 实验与分析	36
3.5.1 实验设置	36
3.5.2 反射分割实验	36
3.5.3 人体分割实验	39
3.5.4 三维重建实验	41
3.6 本章小结	44
第 4 章 基于神经辐射场的室外场景重建	46
4.1 引言	46
4.2 算法框架	47
4.3 基于多视图立体的漫反射场景重建	48
4.3.1 网络整体设计	49
4.3.2 损失函数	50
4.4 基于分块解耦的反射场景重建	50

4.4.1 反射解耦	51
4.4.2 分块渲染	53
4.5 实验与分析	53
4.5.1 实验设置	53
4.5.2 数据集	54
4.5.3 实验结果与分析	54
4.6 本章小结	58
第5章 总结与展望	59
5.1 总结	59
5.2 展望	60
参考文献	62
致 谢	70
在学期间完成的相关学术成果	71

Contents

Abstract-Chinese	I
Abstract-English	II
Contents-Chinese	IV
Contents-English	VII
Chapter 1 Introduction	1
1.1 Background and Significance	1
1.2 Current State of Research	3
1.2.1 Reflections Detection and Segmentation	3
1.2.2 Non-rigid Objects Detection and Segmentation	4
1.2.3 3D Reconstruction Based on Implicit Representation	6
1.3 Research Contents	7
1.4 Organisational Structure	8
Chapter 2 Related Theories and Technologies	10
2.1 Introduction	10
2.2 Attention Mechanisms in Computer Vision	10
2.2.1 Vision Transformer	12
2.2.2 Swin Transformer	14
2.3 Multi-view Stereo	15
2.3.1 Camera Model	15
2.3.2 Epipolar Geometry	18
2.3.3 Triangulation	19
2.3.4 Structure from Motion	19
2.4 3D Reconstruction Based on Neural Radiance Fields	21

2.4.1	Volume Rendering	22
2.4.2	Positional Encoding and Hierarchical Sampling	23
Chapter 3 Image Segmentation in Outdoor Scene Reconstruction		
		23
3.1	Introduction	25
3.2	Algorithm Framework	26
3.3	Reflection Segmentation Based on Multi-view Consistency	27
3.3.1	Overall Network Design	28
3.3.2	Multi-view Consistency	29
3.3.3	Loss Function	30
3.4	Human Segmentation Based on Pose Estimation	31
3.4.1	Multi-person Pose Estimation	31
3.4.2	Overall Network Design	32
3.4.3	Deformable Cross-attention Module	34
3.5	Experiments and Analysis	36
3.5.1	Experimental Setup	36
3.5.2	Reflections Segmentation Experiment	36
3.5.3	Human Segmentation Experiment	39
3.5.4	3D Reconstruction Experiment	41
3.6	Summary	44
Chapter 4 Outdoor Scene Reconstruction Based on Neural Radiance Fields		
		46
4.1	Introduction	46
4.2	Algorithm Framework	47
4.3	Diffuse Scene Reconstruction Based on Multi-view Stereo	48
4.3.1	Overall Network Design	49

4.3.2	Loss Function	50
4.4	Reflective Scene Reconstruction Based on Patch-wise Decoupling	50
4.4.1	Reflection Decoupling	51
4.4.2	Patch-wise Rendering	53
4.5	Experiments and analysis	53
4.5.1	Experimental Setup	53
4.5.2	Dataset	54
4.5.3	Results and Analysis	54
4.6	Summary	58
Chapter 5	Summary and Outlook	59
5.1	Summary	59
5.2	Outlook	60
	References	62
	Acknowledgments	70
	Relevant Academic Achievements Completed During the Academic Period	71

第1章 绪论

1.1 研究背景与意义

三维重建作为计算机视觉、计算机图形学领域的热点课题，通过利用计算机技术将物理世界中的实体建模为三维数字化模型，在三维动画制作、虚拟现实与增强现实、游戏开发以及医学三维图像等领域有着广泛的应用，因此引起了研究人员的广泛关注。目前，研究人员广泛使用的三维重建技术主要包括：直接人工操作的三维建模技术、扫描三维重建技术以及基于三维视觉的多视图重建技术。

直接人工操作的三维建模技术是指 3D 建模师使用三维建模软件，例如 Blender、Maya、Unity 等业界广泛使用的免费开源工具，亲手塑造数字化三维模型的过程。在这一过程中，建模师不仅细致入微地定义模型的几何、材质及动画，而且使用先进的光线追踪算法^[1]对给定相机视角下的三维场景进行高质量渲染。目前，该类三维重建技术已在游戏开发、影视制作、建筑设计等诸多领域得到广泛应用，市场上也有大量专业的软件供用户获取。然而，此种方法高度依赖于 3D 建模师的艺术创作力和建模能力，需要投入大量的人工成本，且制作周期较长。同时由于整个过程完全由 3D 建模师进行人工操控，制作模型常常存在精准度低、真实感差等问题。

扫描三维重建技术是一种利用精确的主动深度传感器对目标物体或场景进行全方位、高精度的扫描，预测其立体深度信息的方法。目前，市场上比较流行的商用传感器，例如 Microsoft Kinect 和 Intel RealSense 等，已在各类场景重建任务中得到广泛应用。这些传感器依靠“主动”发射自身光线，利用红外或飞行时间原理获取精确的场景深度，即使在光线很弱甚至没有光线的情况下也能保持良好的性能。然而，这类传感器的有效运作要求场景表面能够返回强信号，在例如镜子这样的反射表面时会返回错误信号，从而导

致不可靠的深度估计。图 1.1 展示了重建 ScanNet^[2]数据集中一个场景的结果，其中镜面反射的虚像被错误地重建为镜面背后的场景，从而无法正确反映出反射表面的实际深度。该结果表示此类算法在处理反射现象时容易受到干扰，产生糟糕的重建结果。



图 1.1 浴室场景的扫描重建^[3]

基于三维视觉的多视图重建技术是一种通过分析相机采集到的多视角图像，被动地重建三维场景的方法。不同于前两种方法，该方法不需要特殊的硬件设备，仅需普通相机即可开展三维建模，具有成本低、操作简单等优点，因此已成为三维重建领域研究的焦点之一，被广泛地探讨与应用。传统的多视图重建算法基于 2D 图像匹配技术和多视图立体原理，通常包括图像采集、稀疏重建、稠密重建、点云模型化等多个步骤，已在多种简单场景的重建任务中取得了令人满意的结果。其中，运动恢复结构（Structure from Motion, SfM^[4]）和多视图立体（Multi-view Stereo, MVS^[5]）是两个代表性的经典算法。然而，当面对诸如反射强烈的场景或是包含动态对象的复杂场景时，传统的多视图重建算法的特征匹配阶段会受到严重干扰，最终导致重建失败。

随着深度学习的蓬勃发展，越来越多的研究人员开始探索将其引入多视图重建算法中，但该方向的研究整体上仍处于起步阶段。鉴于卷积神经网络在图像特征匹配方面展现出巨大优势，很多研究^[6-8]将其引入传统算法中稀疏重建这一阶段，从而优化三维重建的结果。同时，一些研究^[9-13]则直接利

用深度学习算法,使用神经网络去拟合多视角图像表示的显示三维模型,端到端地实现三维重建过程。然而,将卷积神经网络从 2D 空间泛化到 3D 空间的过程中,其时间复杂性和空间复杂性都会迅速增长,同时经典的显示表示方法如三角形网格等由于其未知的顶点数以及灵活的网络拓扑结构,给神经网络的训练带来了挑战。因此,近年来研究人员开始探索基于隐式表示的三维重建算法,使用神经网络拟合三维模型对应的隐式函数。这种方法使用隐式函数表示 3D 几何,通过学习并重建目标的隐式函数,利用行进立方体算法,最终可以生成网格形式的三维模型,克服了显式模型在分辨率有限和固定网络拓扑方面的局限。

尽管近十年来基于三维视觉的多视图重建技术取得了巨大的进步,但是这些算法都要求重建对象基于朗伯模型的假设,这一前提导致现有算法在处理包含反射特性的场景时,往往暴露其局限性。然而,在实际的室外场景中,诸如高楼大厦的建筑表面、大面积的玻璃门窗等强反射表面极其常见,因此迫切需要能够应对此类问题的高效算法。同时,室外场景中频繁出现的动态非刚体对象,如活动的人群,打破了传统重建方法基于场景静止的假设,也成为阻碍三维重建算法准确性提升的重要因素。

基于以上背景,本文的研究围绕基于三维视觉的多视图重建技术,针对现有方法在处理反射场景和动态非刚体对象时的不足,从图像分割和神经辐射场两个角度对现有技术提出优化方案,显著提高室外场景三维重建的精度。

1.2 国内外研究现状

1.2.1 反射识别与分割

在之前的三维重建算法研究中,水面、玻璃等复杂的反射、透射现象很少被解决,而这对于室外场景重建的精度提升至关重要。**Chang** 等人^[14]在室内场景重建的研究中,为了消除反射与透射表面的干扰,采取了一种人工标注的方法解决该问题,即要求用户手动标注出扫描场景中的反射与透射表面,

有效地提高了三维重建的精度，但是该方法需要大量的人工成本，不利于大规模室外场景重建任务的高效执行。为减轻人工标注带来的负担，Whelan等人^[3]在传感设备上面连接了一个AprilTag^[15]，通过检测AprilTag的存在，自动识别场景中出现的反射、透射表面，同时估计出准确的平面参数，从而准确估计三维场景的深度。尽管这种方法在特定条件下显示出一定的有效性，但是它依赖于复杂的硬件设备，对于大型室外场景的数据采集难度较大。

受到这些工作的启发，识别场景中反射表面的存在可以有效提高室外场景三维重建的精度。不同于其他类型的场景，反射表面没有固定的视觉特征，其外观随观察视角的变化而变化，这种视点依赖性导致普通的图像分割算法无法直接应用于反射场景中。当光线照射到玻璃表面时，大部分光线会进入玻璃，产生折射现象，只有小部分光线会在玻璃表面发生反射。基于这样的观察，一些研究利用场景表面的平滑性^[16, 17]、稀疏性^[18]和重影^[19]等先验知识，识别玻璃表面的存在，并尝试将场景分解为透射场景与反射场景两个组件。在最近的一些基于深度学习的研究中，一些研究者^[20-22]基于镜面边界处不连续性以及上下文语义信息，成功地识别并分割出镜面区域。

总体来说，尽管当前针对反射分割的研究已取得一些进展，但是对该问题的深入研究仍然不足，对于反射表面特征的深入理解和有效建模仍然是未来三维重建领域亟待突破的课题。

1.2.2 非刚体检测与分割

与单一实体重建或室内场景重建任务不同，室外环境下的三维场景通常存在很多动态非刚体对象，如行人、昆虫、植物等，其中人类因其数量众多以及社会活动中的主导性地位，成为当前三维重建领域主要关注的非刚体对象。传统的三维重建算法基于场景中的特征点恢复三维信息，然而人类频繁且多变的运动行为会严重干扰特征点的提取与匹配，从而导致这些算法无法适用于大型的室外场景重建任务。面对这一难题，目前大多数算法通过将三维重建算法与图像分割任务紧密结合，以更有效地处理三维场景中的复杂物

体，进而提升重建效率与精度。因此本文将重点研究人体分割算法，旨在将室外场景中存在的人体实例分割出来，消除其对特征匹配阶段的干扰，从而有效地提高三维场景重建的精度。

人体分割，作为计算机视觉领域的一个重要分支，专注于从图像或视频中准确地检测并分割出人体的轮廓边界。当前精度领先的人体分割算法普遍采用通用的实例分割框架^[23-26]，这些框架大多基于强大的实例检测方法，首先检测出人体所在区域，再对区域内进行精细化的语义分割。因此，人体检测作为人体分割至关重要的前置步骤，其性能直接决定了后续人体分割阶段的效果。在深度学习技术兴起之前，早期的人体检测算法^[27, 28]主要依赖于手工设计的特征和传统的机器学习算法，例如 Haar 特征^[29]因其在人脸检测领域的成功应用而广为认知、HOG 特征^[30]则因其在行人检测任务中的有效性被大量采用、SIFT 特征^[31]则因其在图像匹配任务中的稳健性而备受青睐。这些特征通常与支持向量机^[32]，随机森林，Adaboost^[33]等经典的分类器相结合实现人体检测。虽然这些算法取得了一定的成效，但是在处理复杂环境变化和遮挡等问题时，鲁棒性较差。随着深度学习技术的崛起，基于深度学习的人体检测算法开始大放异彩，他们在各类数据集上的表现远远超过传统的手工特征。基于区域提议的方法，如 R-CNN^[34]、Fast R-CNN^[35]、Faster R-CNN^[36]等，通过生成一系列候选区域，然后再进行精细的检测，大幅提高了检测的准确度。与此同时，端到端的检测方法，如 YOLO^[37]、SSD^[38]等不使用区域提名，直接从图像中预测边界框和类别，尽管大幅提升了检测速度，满足了实时处理的需求，但是在精度方面低于基于区域提议的方法。

为了将人类丰富的特定领域知识引入人体分割任务中，以提升对人体轮廓精细化识别的能力，一些研究开始探索将姿态估计技术与人体分割技术相结合，从而实现高精度的人体分割结果。其中，Tripathi 等人^[39]将人体姿态估计作为人体分割的先导步骤，其输出被用作先验知识引导实例分割。这种方法有效地将人体的关键点信息融入分割任务中，提高了人体分割的准确性。Papandreou 等人^[40]将人体分割看作逐像素聚类的问题，使用自下而上的姿态

估计结果来细化聚类结果。虽然该方法在精度上未能超越通用的实例分割算法 Mask R-CNN，但是它为处理人体分割问题提供了不同的视角，揭示了姿态信息在提高分割质量方面的巨大潜力。Zhang 等人^[41]同样采用自下而上的姿态估计算法，提取出人体骨架信息，并结合独特的仿射对齐操作，超越了传统基于人体检测算法的分割模型，同时在处理复杂遮挡方面展现出了卓越的准确性。

总体来说，尽管将姿态信息引入人体分割任务的研究较少，但是已有的研究成果证明了该研究路径的潜在价值和可能性。然而，如何设计出能够充分融合人体姿态信息，又能与实例分割算法相适应的高效网络架构，是当前领域的一项重要挑战。

1.2.3 基于隐式表示的三维重建

近年来，基于隐式表示的三维重建算法引起了广泛关注，与传统方法依赖于点云、网格等显式的几何表示不同，这类方法为复杂的三维形状和拓扑结构提供了一种更加灵活和强大的表示方式，不仅能够连续地表示三维信息，不受分辨率的限制，同时占用内存资源较小，展现出重建传统方法难以应对的复杂对象的潜力。在早期的工作中，Park 等人^[42]提出 DeepSDF 方法使用神经网络拟合符号距离函数，从嘈杂的输入数据中恢复物体高质量的三维几何结构，具有强大的表征能力。Mescheder 等人^[43]提出 Occupancy Networks 方法使用神经网络输出连续的边界决策来定义三维物体的表面，展示出竞争力的三维重建能力。尽管这些方法都可以从不完整的数据中重建出高质量的三维模型，但是他们在表达细节和处理模糊形状上存在一定的挑战，常常需要附加额外的约束，如深度信息、对象掩码等。

2020 年神经辐射场（Neural Radiance Fields, NeRF^[44]）的提出实现了隐式表达三维场景方法上的重大突破，为各类三维重建任务提供了新的思考和启发。NeRF 仅需要输入稀疏视角的二维图像，便可以学习出三维场景的颜色与密度，生成高质量的三维场景和逼真的图像渲染，大大减少了输入数

据量，与传统的三维重建方法相比，具有无限分辨率、易于学习、泛化性强等优点。但是 NeRF 只针对小规模和以对象为中心的重建，并且只能处理一些简单的遮挡和反射，无法解决在自然光下，水面、玻璃表面复杂的反射与透射现象，因此 NeRF 难以扩展到复杂的室外场景重建。之后的一些研究扩展了 NeRF 的工作，使其适应于室外场景重建。Wild-NeRF^[45]弥补了 NeRF 中建模对象只能是静态环境的不足，一定程度上缓解了建模中可变照明和瞬时遮挡的问题，仅使用非结构化的图像集就可以重建出真实的室外场景。Block-NeRF^[46]将城市场景分解为多个单独训练的 NeRF，将渲染时间与场景大小分离，使重建可以扩展到任意规模的场景，并且允许对场景逐块更新。Urban Radiance Fields^[47]利用 RGB 图像和激光雷达扫描数据，弥补了在复杂场景中视点的稀疏性，同时结合雷达数据的损失，允许对固体结构（如建筑物）和体积结构（如树木、植被）进行精确的表面估计。

尽管针对 NeRF 的优化研究在过去几年层出不穷，但是对于反射现象的有效处理仍然探索不足。因此，当前领域需要能够有效融入 NeRF 框架中的创新算法，以应对包含复杂反射现象的场景重建任务，进一步拓宽 NeRF 的应用领域，使之在更广泛的现实世界中发挥强大的性能。

1.3 主要研究内容

近年来，三维重建领域取得了很大进展，我们可以通过各种三维重建方法得到高质量的场景几何和纹理信息。然而，当应对室外场景的多重复杂性时，特别是室外场景中普遍存在的反射现象和频繁出现的动态非刚体对象，现有算法的表现往往不佳。这些因素对传统三维重建框架中的特征匹配阶段产生了严重干扰，进而影响了后续重建结果的质量。为了克服这些难题，本文从图像分割和神经辐射场两个角度出发，分别提出简单有效的优化方案，同时图像分割方法可作为神经辐射场方法的前置步骤，旨在提高基于三维视觉的多视图重建技术在室外场景应用中的准确性和鲁棒性。主要的研究内容如下：

(1) 室外场景重建中的图像分割。本文将基于深度学习的图像分割算法融入传统的多视图重建算法流程中,有效地消除了反射表面和非刚体对象对室外场景重建造成的负面影响,从而提高室外场景重建的精度。具体来说,针对反射表面视点不一致性所导致的室外场景重建精度下降的问题,本文提出了一种反射分割算法,将多视图一致性原则与深度学习技术相结合,能够准确分割出室外场景中的反射区域,从而消除反射表面对三维重建算法的干扰。同时,针对传统算法在处理人类运动时精度损失的问题,本文提出了基于姿态估计的人体分割算法,结合有效的人体检测方案以及精心设计的网络架构,将姿态信息与人体分割任务深度融合,实现在室外场景下高精度的人体分割,从而显著提升三维重建的质量。

(2) 基于神经辐射场的室外场景重建方法。针对现有神经辐射场在室外场景重建应用中的局限性,特别是其固有的几何模糊和无法有效渲染高频反射信息的不足,本文提出基于神经辐射场的室外场景重建算法,优化和改进传统的神经辐射场,使其适用于复杂的室外场景重建中。具体来说,针对神经辐射场在几何表达上的模糊性问题,本文提出基于多视图立体的优化算法,利用传统的多视图立体算法得到的深度先验信息,引导神经辐射场学习出精确的场景几何,该算法显著提高了漫反射场景重建的几何精度。同时,为了实现对反射表面的精确建模,本文提出基于分块解耦的优化算法,将反射纹理与透射场景成功分离,不仅正确估计出反射表面的深度,还精确渲染出反射表面随视点变换而变化的高频细节。

1.4 论文组织结构

本文总共包含五个章节,每个章节的主要内容如下:

第一章,绪论。在这一章节中,首先介绍了三维重建技术的研究背景与重要意义,同时指出现有技术在室外场景应用中面临的挑战。通过对国内外研究现状的深入剖析,明确本文旨在解决的关键技术难题。在此基础上,确定了本文的研究目标、主要研究内容,并对论文的整体组织结构进行概述。

第二章，相关理论和技术。在这一章节中，首先介绍了 Transformer 的基础理论及其在视觉领域的相关研究，然后介绍了传统多视图重建算法中的核心理论与关键技术，最后对新兴的神经辐射场的理论进行了详尽的介绍。这些理论的探讨为理解本文提出的方法和实验提供了必要的理论支撑，并为本文研究工作的展开奠定了坚实的基础。

第三章，室外场景重建中的图像分割。在这一章节中，主要介绍了本文提出的基于图像分割的室外场景重建方法，并重点介绍了两个核心算法：基于多视图一致性的反射分割算法和基于姿态估计的人体分割算法。本章通过使用开源软件 RealityCapture 实现三维重建的完整流程，结合实验结果的详尽展示与分析，验证了所提出的方法在室外场景重建任务中的有效性。

第四章，基于神经辐射场的室外场景重建。在这一章节中，主要介绍了本文提出的基于神经辐射场的室外场景重建算法，并详细介绍了两个核心算法：基于多视图立体的漫反射场景重建和基于分块解耦的反射场景重建。通过对这两种算法的设计思路、实现细节和实验结果进行详尽的展示与对比分析，充分证明了该算法在处理室外场景时的优越性能。

第五章，总结与展望。在这一章节中，对全文的研究内容进行了系统地回顾与总结，同时也客观地指出当前研究存在的局限与未来改进的空间。在此基础上，对未来的研究方向进行了展望。

第2章 相关理论和技术

2.1 引言

近年来, Transformer^[48]在自然语言处理领域取得的巨大成功, 启发研究人员将其迁移到计算机视觉任务上, 包括图像分割, 展现出了超越传统方法的卓越性能。在图像分割任务中, Transformer 帮助模型理解图像中的不同区域, 通过对 Transformer 基础理论及相关研究的深入学习与理解, 启发对其进行改进与优化, 以期实现图像分割任务的性能提升。多视图立体是指用几何的方法, 利用不同视角下获取的二维图像信息, 恢复相机参数和场景的三维信息。作为传统三维重建算法的核心理论, 深入理解其原理对于推动三维重建算法的发展与创新十分关键。神经辐射场作为一种新兴的三维重建技术, 凭借其独特的场景表示方式, 引发了研究人员在三维重建任务上新的思考和启发。对于神经辐射场的改进和优化已成为当前领域的热点课题, 通过对其理论的深入学习与理解, 启发将其应用于解决本文所关注的相关问题, 拓宽其应用领域的范围。

本章将重点介绍本文所提算法的相关理论和技术。2.2 介绍了计算机视觉中的注意力机制的基础理论和相关研究; 2.3 介绍了多视图立体的几何原理和相关技术; 2.4 介绍了神经辐射场的基础理论。

2.2 计算机视觉中的注意力机制

Transformer 在自然语言处理领域取得了革命性进展, 被广泛应用于如机器翻译、文本生成、问答系统等任务, 相较于传统的递归神经网络和卷积神经网络, Transformer 具有出色的并行计算能力, 允许高效地处理长序列数据。

如图 2.1 所示, Transformer 的网络架构主要由编码器和解码器两大部分

组成。其中编码器由 N 个重复的层堆叠构成，每一层内部包含两个子模块，第一个子模块是多头注意力模块，这一模块通过将注意力机制划分为多个并发的注意力头，每个头关注输入序列的不同子特征，可以捕捉序列数据之间复杂的依赖关系。这种并行化处理不仅显著增强了模型的表征能力，同时大幅提升了计算效率。第二个子模块是简单的全连接前馈层，用于处理多头注意力模块输出的信息，对其进行深度特征提取，进一步增强表达能力。解码器的构造与编码器类似，也是由 N 个重复的层堆叠而成，但是在设计上引入了针对生成任务的特有调整。解码器的第一个子模块采用掩膜多头注意力模块，此处的注意力计算受到约束，每个元素仅能关注其之前序列位置的元素，以避免未来信息泄露，确保生成信息的逻辑连贯性。第二个子模块是解码器所特有的，用于对编码器的输出进行注意力加权，从而充分挖掘输入序列的特征信息，结合当前解码阶段已生成的部分信息，共同指导后续预测的生成。第三个模块与编码器相同，也是简单的全连接前馈层，负责对解码器生成的向量进行非线性变换。




图 2.1 Transformer 的网络架构图^[48]

通过精心设计的编码器与解码器架构，以及高效的多头注意力机制，Transformer 实现了对长序列的上下文信息捕捉能力，成为现在自然语言处理领域的主流模型。

Transformer 的算法核心是引入了独特的自注意力机制，其本质是通过模仿人类的认知系统，使神经网络具有自主关注输入序列中重要信息的能力，从而提高模型的性能和泛化能力。自注意力机制可以将序列中的每个元素与其他元素建立关联，并自适应地捕捉它们之间的依赖关系。这一机制的实现主要得益于三个重要的输入矩阵：查询矩阵（Query, Q）、关键矩阵（Key, K）和数值矩阵（Value, V）。Q 表示当前元素的信息，K 则表示所有元素的信息，通过 Q 与 K 相乘可以得到一个权重分布。该分布体现了当前元素与其他元素之间的关系，权重值越大，表明两个元素间的关系越密切。随后这个权重分布再与 V 计算加权和，得到一个新的向量。该向量包含了与当前元素相关联的其他所有元素的重要信息，可以表示为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \quad (2-1)$$

交叉注意力机制^[49]是自注意力机制的一个重要扩展，旨在处理多个序列之间的关系。通过允许一个序列的查询矩阵 Q 与另一个序列的关键矩阵 K 和数值矩阵 V 进行计算，实现跨序列之间的信息流动，显著增强了模型捕捉不同序列之间依赖关系的能力，从而提高模型性能。鉴于其在跨序列信息处理上的独特优势，交叉注意力机制对于需要精细处理序列间信息的应用场景展示出无可替代的重要性，如机器翻译、多模态处理、问答系统等，成为多模态学习及其相关领域的重要方法。

2.2.1 Vision Transformer

随着 Transformer 在自然语言处理领域取得的巨大成功，其概念和架构逐渐被引入计算机视觉领域。其中，视觉 Transformer（Vision Transformer, ViT^[50]）通过将 Transformer 代替传统的卷积结构，使用注意力机制捕获图

像的上下文信息，在图像分类任务上取得了卓越的表现。这一突破性成功标志着 Transformer 在计算机视觉领域应用的重要突破，同时推动了一系列后续的研究，进一步挖掘 Transformer 在视觉领域的潜能。

如图 2.2 所示，ViT 的网络架构主要包含三个模块：嵌入层、编码器、分类层。为了适配 Transformer 的架构，ViT 首先将图像数据转换为序列数据。具体来说，ViT 将输入图像划分成若干个小块，这些小块通过嵌入层映射成一维向量，成功转换为适用于 Transformer 的序列形式。为了执行图像分类任务，ViT 在输入序列中加入了一个“类别”令牌，该令牌的输出为最终预测的类别标签。此外，ViT 还在每个输入向量中加入了位置编码来赋予模型空间感知能力，确保序列中的各个元素的位置信息得以保留。这些向量随后被输入到 Transformer 编码器中，通过多个堆叠的层计算全局空间注意力。最后经过分类层的处理，输出预测的类别标签。




图 2.2 ViT 的网络架构图^[50]

ViT 成功将 Transformer 架构迁移到计算机视觉领域，不仅在图像分类任务上超越了传统方法的性能，更推动了 Transformer 在目标检测、图像分割等视觉任务中的广泛应用。

2.2.2 Swin Transformer

将 Transformer 从自然语言处理领域迁移到图像领域时，存在两个重大挑战。首先，视觉世界固有的尺度变化特性，导致 ViT 的性能在某些场景表现不佳。其次，图像的高分辨率意味着其信息量远超文本数据，直接使用自注意力机制进行处理，会导致计算成本的急剧增加。为了解决以上问题，Swin Transformer^[51]提出了一种创新的分层结构，通过采用滑动窗口的方法，将自注意力计算限制在非重叠窗口内，并且允许跨窗口的连接，在提升性能的同时，显著降低了计算复杂度。




图 2.3 Swin Transformer 的网络架构图^[51]

如图 2.3 所示，Swin Transformer 的网络架构采取层次化的设计，包含四个阶段。每个阶段都通过降低输入特征图的分辨率，逐层扩大模型的感受野，以捕获不同尺度的视觉特征。模型首先将输入图像划分为若干不重复的小块，然后将这些块的特征输入各个阶段中进行编码。在每个阶段内部，由线性嵌入层和多个 Swin Transformer 基础模块（Swin Transformer Block）组成，其中线性嵌入层主要在每个阶段开始前降低图像分辨率并调整通道数，进而形成层次化的设计。Swin Transformer Block 作为算法的核心模块，主要包含归一化层、窗口注意力（Window Multi-head Self Attention, W-MSA）模块和滑动窗口注意力（Shifted Window Multi-head Self Attention, SW-MSA）

模块。与传统的 Transformer 基于全局计算注意力不同，Swin Transformer 在局部窗口中计算注意力，显著减少了计算量。此外，为了促进不同窗口之间的信息交互，Swin Transformer 还引入了滑动窗口的操作，通过设置合理的掩膜，确保滑动窗口模块和窗口模块具有相同数量的窗口，实现等价的计算代价。通过这些巧妙的设计，使得 Swin Transformer 的计算复杂度仅随图片大小呈线性增长，同时扩展了其在视觉任务上的兼容性，如物体检测、语义分割等复杂场景。

2.3 多视图立体几何

2.3.1 相机模型

相机成像的过程是将空间中的三维点映射为二维图像上的像素点的过程，这一过程可以简化为小孔成像模型。如图 2.4，空间中的三维点 P 通过光心 O_c 投影为像素平面上的点 P' ，将光心看作小孔，任何来自真实世界的光通过小孔到达像素平面形成最终图像。深入理解相机成像过程，可以建立三维场景中的三维点与二维图像中的像素点之间的映射关系。这种映射关系构成了计算机视觉、三维重建等领域理论研究的重要基石，是实现从数字世界到物理世界转换的关键。

在相机成像的过程中，涉及 4 个坐标系的转换：

(1) 世界坐标系：描述三维点 P 在真实世界中的坐标 (X_w, Y_w, Z_w) ，原点 O_w 可以任意选择。

(2) 相机坐标系：以相机的光心 O_c 为坐标原点，相机的光轴为 Z_c 轴， X_c 轴和 Y_c 轴平行于成像平面，构成相机坐标系 (X_c, Y_c, Z_c) 。

(3) 图像坐标系：以成像平面的中心 O 为坐标原点， x 轴和 y 轴平行于成像平面，构成图像坐标系 (x, y) 。

(4) 像素坐标系：以成像平面的左上角顶点为原点 o ， u 轴和 v 轴平行于成像平面的两条边，构成像素坐标系 (u, v) 。




图 2.4 小孔成像模型

世界坐标系通过平移、旋转得到相机坐标系，其中 R 代表旋转矩阵， t 代表平移矩阵。

$$\begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix} = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix} \quad (2-2)$$

相机坐标系通过透射投影变换得到图像坐标系，实现 3D 点 (X_c, Y_c, Z_c) 到 2D 点 (x, y) 的映射，其中 f 为相机焦距。

$$z_c \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x_c \\ y_c \\ z_c \\ 1 \end{bmatrix} \quad (2-3)$$

图像坐标系通过仿射变换得到像素坐标系，其中 u_0 、 v_0 是图像坐标系的原点在像素坐标系下的坐标， d_x 、 d_y 表示像素的分辨率大小。

$$\begin{cases} u = u_0 + \frac{x}{dx} \\ v = v_0 + \frac{y}{dy} \end{cases} \quad (2-4)$$

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{dx} & 0 & u_0 \\ 0 & \frac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (2-5)$$

通过这三次变换,可以得到世界坐标系下点 P 到像素坐标系下 P' 的转换公式,其中 K 称为相机内参矩阵, T 称为外参矩阵,可以通过相机标定求得相机的内参矩阵和外参矩阵。

$$z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \underbrace{\begin{bmatrix} \frac{1}{dx} & 0 & u_0 \\ 0 & \frac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix}}_{\text{仿射变换}} \underbrace{\begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}}_{\text{透射投影}} \underbrace{\begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix}}_{\text{刚体变化}} \begin{bmatrix} x_w \\ y_w \\ z_w \\ 1 \end{bmatrix} \quad (2-6)$$

$$z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \underbrace{\begin{bmatrix} f_x & 0 & u_0 & 0 \\ 0 & f_y & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}}_{\text{内参矩阵}} \underbrace{\begin{bmatrix} R & T \\ 0 & 1 \end{bmatrix}}_{\text{外参矩阵}} \begin{bmatrix} x_w \\ y_w \\ z_w \\ 1 \end{bmatrix} \quad (2-7)$$

$$z_c \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = KT \begin{bmatrix} x_w \\ y_w \\ z_w \\ 1 \end{bmatrix} = P \begin{bmatrix} x_w \\ y_w \\ z_w \\ 1 \end{bmatrix} \quad (2-8)$$

事实上,在真实的相机成像过程中还存在径向畸变和切向畸变。径向畸变是由透镜的形状引起的,可以使用泰勒级数展开式进行矫正,如公式(2-9)。而切向畸变是由于在相机组装过程中,透镜的安装与成像平面不平行引起的,可以使用公式(2-10)进行矫正。

$$\begin{cases} x_{corrected} = x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \\ y_{corrected} = y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \end{cases} \quad (2-9)$$

$$\begin{cases} x_{corrected} = x + [2p_1y + p_2(r^2 + 2x^2)] \\ y_{corrected} = y + [2p_2x + p_1(r^2 + 2y^2)] \end{cases} \quad (2-10)$$

2.3.2 对极几何

对极几何^[52]描述一对图像之间内在的射影几何关系。如图 2.5，假设存在一个空间点 P ， O_1 、 O_2 分别代表两个相机的光心， P 、 O_1 与 O_2 与构成极平面，极平面与两个图像的交线称为极线 l_1 、 l_2 ，那么就存在一种几何约束：已知图像 1 中存在一点 P_1 ，则在图像 2 的极线上必存在一点 P_2 与之匹配，这就称为对极几何约束。

通过利用对极几何约束，可以求解相机的相对运动以及三维空间点的位置信息。设空间点 $P = (X, Y, Z)$ ，则两幅图像中的对应点 p_1 、 p_2 的关系为 $p_2 F p_1 = 0$ ，其中 F 称为基础矩阵，描述相机内参和外参， $F = K^{-T} T' R K^{-1}$ 。经过归一化操作， p_1 、 p_2 的归一化坐标 $x_1 = K^{-1} p_1$ ， $x_2 = K^{-1} p_2$ ，且 $x_2 E x_1 = 0$ ， $E = T' R$ 称为本质矩阵，描述相机的外参。




图 2.5 对极几何关系图

通常来说，基于图像的匹配算法可以得到一系列匹配的特征点，利用这些特征对，可以求得基础矩阵。对于一对匹配的特征点 $x_1 = [u_1, v_1, 1]^T$ ， $x_2 =$

$[u_2, v_2, 1]^T$ 根据对极几何约束可以表示为:

$$(u_2 \quad v_2 \quad 1) \begin{bmatrix} F_{11} & F_{12} & F_{13} \\ F_{21} & F_{22} & F_{23} \\ F_{31} & F_{32} & F_{33} \end{bmatrix} \begin{pmatrix} u_1 \\ v_1 \\ 1 \end{pmatrix} = 0 \quad (2-11)$$

每一对匹配的特征点提供一个约束, 为了保证存在唯一的解, 至少需要 8 对匹配的特征点, 目前最常使用 8 点法^[53]和随机抽样一致 (Random Sample Consensus, RANSAC^[54]) 求解基础矩阵。

2.3.3 三角化

三角化^[55]是指利用对极几何求得的相机位姿和二维图像的特征匹配点计算得到空间点的三维坐标。

对于空间中的一点 $X = [x, y, z]^T$, 已知相机的外参 $T = [r_1; r_2; r_3] = [R \ t]$, 对应的二维点归一化坐标 $x = [u, v, 1]^T$, 根据前文介绍的相机模型, 则可以表示为:

$$\begin{aligned} \hat{x}^T X &= \begin{bmatrix} 0 & -1 & v \\ 1 & 0 & -u \\ -v & u & 0 \end{bmatrix} \begin{bmatrix} r_1 \\ r_2 \\ r_3 \end{bmatrix} X \\ &= \begin{bmatrix} -r_2 + vr_3 \\ r_1 - ur_3 \\ -vr_1 + ur_2 \end{bmatrix} X = 0 \end{aligned} \quad (2-12)$$

根据线性代数的基本概念, 通过构建两个及以上的线性方程组可以求解得到 X 的坐标, 方程组可以表示为:

$$\begin{bmatrix} -r_2^{(1)} + v^{(1)}r_3^{(1)} \\ r_1^{(1)} + u^{(1)}r_3^{(1)} \\ -r_2^{(2)} + v^{(2)}r_3^{(2)} \\ r_1^{(2)} + u^{(2)}r_3^{(2)} \\ \vdots \end{bmatrix} X = 0 \quad (2-13)$$

2.3.4 运动恢复结构

运动恢复结构作为传统多视图重建算法中的核心环节, 旨在从一系列多视角图像中重建出场景的稀疏三维结构, 并输出相机的内外参数, 为后续的稠密重建

阶段提供坚实的基础。随着技术的不断进步,各种优秀的运动恢复结构算法被提出,其中主要包括增量式 SfM^[4, 56-60]和全局式 SfM^[61-67]。全局式 SfM 采取一次性全局优化的策略,可以一次性求解所有的相机参数和三维信息。其优势在于只需在最后阶段进行一次光速法平差 (Bundle Adjustment, BA^[68]) 优化,因此该类算法在效率上具有显著优势。然而,全局式 SfM 在面对图像噪声和异常情况时,鲁棒性较差,易受局部误差影响。相较之下,增量式 SfM 采取逐步配准与优化的策略,每次新增一幅图像时,对其与现有模型进行配准,并进行一次 BA 优化,逐步构建三维模型与相机参数。虽然这种方法在效率上略逊于全局式 SfM,但是其鲁棒性与准确性得到显著性提升,能更好地应对大规模的复杂室外场景。因此本文将重点关注增量式 SfM 算法的研究与应用,以期在室外场景重建中取得更好的重建效果和准确性。

在增量式 SFM 算法中,主要包括对应查找和增量重建两个关键阶段。在第一个阶段,算法会利用先进的图像匹配技术,寻找输入图像 $I = \{I_i \mid i = 1 \dots I_l\}$ 之间的匹配关系,并基于对极几何原理验证潜在的匹配点。同时,为了进一步增强匹配结果的稳健性,经典的方法如 RANSAC 被广泛应用,以剔除由噪声引起的误匹配。经过严格的几何验证,该阶段最终输出通过几何验证的图像对 $C = \{\{I_a, I_b\} \mid I_a, I_b \in \mathcal{I}, a < b\}$ 以及场景图。所谓场景图是一种以图像作为节点,经过验证的图像对作为边的特殊图结构。这个阶段的目的主要是为了建立图像之间的对应关系,为后续的增量重建提供基础。第二个阶段在第一个阶段的基础上,将已确立的图像对应关系转化为三维空间信息,场景图被用来估计配准图像的姿态 $P = \{p_c \in SE(3) \mid c = 1 \dots N_p\}$, 并生成稀疏的三维点集 $X = \{x_k \in \mathbb{R}^3 \mid k = 1 \dots N_x\}$ 。主要过程如下:

(1) 初始化图像对: 选取一对经过验证的图像对作为重建起点,通常选择最多匹配点数的图像对,以确保初始三维模型的可靠性。

(2) 获取下一张最佳匹配图像: 识别与当前场景拥有最多匹配点数的新图像,确保增量重建的有效性。

(3) 相机参数估计与图像配准: 基于 PnP^[54]算法求解相机参数,将新图像

配准到当前场景。

(4) 三角化得到新的三维点集：基于新配准的图像与现有模型，执行三角化操作得到新的空间点，进一步丰富场景的稀疏点云。

(5) 全局优化：基于 BA 算法对所有相机参数和三维点集进行非线性联合优化以获得最佳的重建结果。

2.4 基于神经辐射场的三维重建

神经辐射场^[44]是一种在 2020 年兴起的全新三维建模方式，其逼真的视图合成效果引起了研究人员的广泛关注。近年来，基于神经辐射场的算法不断涌现，视图合成质量也在逐步提升。这些进展为三维建模和渲染技术的发展带来了新的可能性，为虚拟现实和计算机图形学领域带来了更多的创新机会。




图 2.6 NeRF 算法概述图^[44]

传统的三维表示有体素、点云、网格，能够直观地展示出三维场景的几何信息。与这些传统的显示表示不同，神经辐射场使用神经网络隐式地表示三维场景，仅利用相机参数和稀疏的多视角图像，实现从新的视角下渲染出逼真的二维图像。如图 2.6 所示，神经辐射场将场景建模为连续的 5D 辐射场，输入为空间点的三维坐标 $X = (x, y, z)$ 和相机的观察方向 (θ, ϕ) ，输出为该点的颜色值 RGB 和体素密度 σ ，通过简单的多层感知机学习 (x, y, z) 到

(RGB, σ)的映射，然后使用经典的体渲染方程^[69]将空间中三维点的颜色和密度信息映射为二维图像，最终通过最小化渲染图像与真实图像的误差优化神经网络。

2.4.1 体渲染

体渲染是指从相机光心发出一条射线，将这条射线经过的三维场景渲染到二维图像上这一过程。将相机发出的射线表示为 $r(t) = o + td$ ，其中 o 为相机光心， d 为射线方向， t 为空间中的三维点到达相机光心的距离，最终图像中像素的颜色可以表示为：

$$C(r) = \int_{t_n}^{t_f} T(t) \sigma(r(t)) c(r(t), d) dt, \quad (2-14)$$

$$T(t) = \exp \left(- \int_{t_n}^t \sigma(r(s)) ds \right), \quad (2-15)$$

其中， t_n 、 t_f 分别表示场景中距离相机最近的边界和最远的边界，这个可以通过上一节介绍的运动恢复结构算法获得。 $T(t)$ 表示从 t_n 到 t 光线累积的透射率，即光线到达位置 t 时光强的大小。当光线穿过三维场景时，光线与物体发生碰撞，部分光线被吸收、发射，因此位置 t 处的颜色应该由到达这一点的光线累积的颜色决定。

由于公式 2-14 为连续积分形式，在实际的网络训练中是无法实现的，因此通过可微求积将该渲染方程改写为近似的离散形式进行渲染。使用简单的分段随机采样算法将 t_n 到 t_f 划分为 N 个区间，然后从中随机抽取一个采样点代表该区间的颜色，因此 t 可以表示为：

$$t_i \sim \mathcal{U} \left[t_n + \frac{i-1}{N} (t_f - t_n), t_n + \frac{i}{N} (t_f - t_n) \right] \quad (2-16)$$

通过采样一系列离散点，可以将三维场景可微的渲染为二维图像，最终的渲染方程表示为：

$$\hat{c}(r) = \sum_{i=1}^N T_i \left(1 - \exp(-\sigma_i \delta_i)\right) c_i \quad (2-17)$$

$$T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right) \quad (2-18)$$

2.4.2 位置编码和分层采样

神经辐射场的原始工作中引入了位置编码和分层采样两个关键的改进，以便更好地表示高分辨率的复杂场景。

在神经辐射场中，位置编码扮演着重要的角色。由于神经辐射场采用简单的多层感知机作为网络架构，这种架构存在固有的推理偏差，倾向于学习低频信息，从而难以捕捉高频变化的特征。为了克服这一限制，位置编码被引入，使得神经辐射场可以更准确地表达不同位置的细节和结构，为复杂场景的渲染提供更精确的表示。具体来说，位置编码通过对三维点的坐标和观察向量进行重新映射，将它们转换到更高维度的特征空间中。这种转换使得多层感知机能够更好地捕捉高频变化的特征，从而提高渲染质量和真实感。

另一方面，分层采样策略的应用不仅提高了神经辐射场的渲染效率，还使其能够更好地处理大规模、复杂的场景，展示出逼真和细节的渲染效果。相比于简单的分段随机采样，分层采样可以灵活地根据场景的复杂性和细节程度进行采样，避免对场景中的空白区域进行重复采样，从而在保证渲染质量的同时降低计算成本。具体来说，分层采样策略将神经辐射场的渲染过程分为两个阶段：粗糙渲染和细致渲染。在粗糙渲染阶段，通过简单的分段采样对“粗网络”进行评估，得到每个采样点的权重，对其进行权重归一化生成概率密度函数，从而指导更加高效的采样，让采样样本更加集中在有重要贡献的场景上，然后评估“细网络”。

最终的损失函数就是简单的渲染图像与真实图像之间的误差平方，可以表示为：

$$\mathcal{L} = \sum_{\mathbf{r} \in \mathcal{R}} [\|\hat{\mathcal{C}}_c(\mathbf{r}) - \mathcal{C}(\mathbf{r})\|_2^2 + \|\hat{\mathcal{C}}_f(\mathbf{r}) - \mathcal{C}(\mathbf{r})\|_2^2], \quad (2-19)$$

其中 $\mathcal{R}$ 为光线集合， $\hat{\mathcal{C}}_c(\mathbf{r})$ 是粗网络的渲染颜色， $\hat{\mathcal{C}}_f(\mathbf{r})$ 是细网络的渲染颜色， $\mathcal{C}(\mathbf{r})$ 是真实颜色值。

位置编码和分层采样这两项关键改进为神经辐射场带来了显著的性能提升，使其能够更好地应对高分辨率、复杂场景的渲染需求，为用户提供更加真实、细致的视觉体验。

第3章 室外场景重建中的图像分割

3.1 引言

传统的三维重建算法依赖于特征点匹配的结果恢复场景的三维信息，在这一过程中，图像匹配算法的精度对最终重建结果的准确性至关重要。然而在复杂的室外场景中，常常包含弯曲的反射表面和多个非共面的反射表面，自然光在这些表面发生复杂的反射和折射效应，这些现象破坏了图像之间的视点一致性，从而削弱了特征匹配算法的性能，严重降低了匹配结果的准确性，最终导致重建质量不佳。如图 3.1 所示，玻璃窗作为典型的反射与折射材质，其引发的光学现象显著扭曲了场景的空间信息，导致如窗框、墙面等结构出现明显的几何失真。此外，人类作为室外场景中的最主要的动态、非刚体对象，其存在不仅增加了场景的多样性，也大幅提升了算法分析的难度。



图 3.1 反射表面对重建带来的影响

为了适应复杂室外场景下的特征提取与匹配过程，当前研究领域亟需设计更加适应性的算法，以提高三维重建技术的整体表现。三维重建技术与图

像分割算法相结合是深度学习背景下三维重建领域中的一个重要方向，并且这种结合也被证明是提高三维重建精度的有效方法。因此本章提出基于图像分割的室外场景重建方法，将图像分割算法与三维重建技术进一步结合，适应于复杂的室外场景重建。相较之前的工作，该算法展现出处理反射现象和动态非刚体对象的独特优势，可以重建出更加准确的室外场景几何，大幅提升了三维重建结果的质量和精度。

本章将详细介绍本文提出的基于图像分割的室外场景重建方法。3.2 概述了该方法的总体框架；3.3 介绍了基于多视图一致性的反射分割算法的设计与实现；3.4 介绍了基于姿态估计的人体分割算法的设计与实现；3.5 通过一系列实验验证本章提出的算法，并对实验结果进行详细分析，以证明所提算法的有效性。

3.2 算法框架

在经典的 SfM 算法中，SIFT^[70]特征凭借其卓越的稳健性与尺度不变性，常被用于实现特征匹配阶段。然而，当面对室外场景的复杂性时，SIFT 特征往往出现失配的现象。反射纹理引起的特征误导、人类活动导致的匹配混乱，这些问题构成了导致 SIFT 特征匹配失效的常见诱因，继而导致三维重建失败的情况频繁发生。为了克服这一难题，本章提出了基于图像分割的室外场景重建方法，旨在通过精细化的图像预处理技术，大幅提升 SfM 阶段的匹配准确性，从而确保整个三维重建流程产生精确的重建结果。如图 3.2 所示，该方法主要包含两大模块：图像分割模块和三维重建模块。在图像分割模块中，本文聚焦于室外场景重建任务中的两项关键难题，针对性地提出两个核心算法：

（1）基于多视图一致性的反射分割算法：面对室外场景中普遍存在的反射现象，该算法利用多视图一致性约束，结合新颖的网络架构设计，深度探索不同视角图像间的空间对应关系，精准识别并分割出反射区域，从而有效抑制了反射纹理对特征匹配的负面影响。

(2) 基于姿态估计的人体分割算法：考虑到人类作为室外场景中频繁出现且姿态多变的动态非刚体对象，该算法将人体姿态信息与深度学习驱动的图像分割算法相结合，引导精细化的人体分割，从而消除了因人体运动诱发的错误匹配点。

利用这两个算法完成图像分割预处理后，本文将处理后的无干扰图像基于图像匹配技术和多视图几何立体进行稀疏重建，得到优化后的相机参数和稀疏的三维点云。然后运用稠密重建算法，在稀疏点云的基础上填充缺失的三维细节，生成密集的点云模型。最后经过一系列模型化的后处理步骤，如表面平滑、噪声滤除等，优化模型质量，得到最终精细的三维模型。




图 3.2 基于图像分割的室外场景重建方法的系统框架

3.3 基于多视图一致性的反射分割

反射表面作为室外场景中广泛存在的视觉元素，其独特的光学特性对三维重建任务构成了严峻挑战。为了解决这一难题，本文提出基于多视图一致性的反射分割算法，旨在精确识别并分割出室外场景中的反射区域，为实现高精度的三维重建提供坚实的数据支撑。

在物理世界中，无论是反射表面内部还是外部，多视角图像之间均存在着某种空间对应关系。然而，现有工作通常基于单张图像的空间特征实现反

射分割，忽略了这种对应关系。同时，伴随着相机位姿的改变，这种对应关系呈现出强烈的动态变化，极大地增加了特征建模的复杂性，导致在多视角下准确模拟同一反射面的对应关系十分困难。Lin 等人^[71]提出一种称为 VMDNet 的视频镜像检测方法，该方法通过使用一种双向对应模块在空间和时间上探索视频帧之间的对应关系，从而弥补空间上对应特征的缺失，在镜面检测任务上取得了优秀的结果。受此启发，本文的算法以邻接视角的图像作为输入，充分探索其空间对应关系，以期精准捕捉多视角下的反射区域。同时，为了进一步提升反射分割的准确性，在模型训练期间，本文引入多视图一致性约束，通过精心设计的损失函数，引导网络在学习特征的过程中充分考虑不同视角间的几何一致性，从而显著提升反射表面分割的精度。

3.3.1 网络整体设计

如图 3.3 所示，本文提出的基于多视图一致性的反射分割算法主要包含三个阶段。第一个阶段是特征预提取阶段，旨在从输入图像中提取丰富的低级和高级语义特征。具体来说，首先选取两个相邻视角下的图像作为网络的输入，分别表示为 I^i 、 I^{i+1} ，然后采用预训练的特征提取网络 ResNext-101^[72] 提取图像的多尺度特征。其中，本文采用第 2 层作为低级语义特征 f_{low}^i ，捕捉图像的边缘、纹理等信息；第 5 层则作为高级语义特征 f_{high}^i ，蕴含丰富的场景语义信息。为了进一步增强高级语义特征，本文遵循 DeepLabV3^[73] 的设计，将高级特征输入到空洞金字塔池化（Atrous Spatial Pyramid Pooling, ASPP）模块中，对特征进行多层次、多尺度融合，得到更为丰富的高级语义特征 f_{high}^i 。在第二个阶段，该阶段旨在学习不同视角下观察到的图像之间的空间映射关系，以捕捉反射表面内外内容的对应关系。首先，为了对图像内在的语义关系进行深入建模，将第一阶段得到的高级语义特征输入到全局相关（Global Relation, GR^[74]）模块中，这一过程可以有效地提取出反射表面内外的内容。接着将经过 GR 模块处理后的高级语义特征与预处理阶段获得的低级语义特征分别输入到两个交叉注意力（Cross-Attention^[71]）模块中。

这些模块的设计旨在自适应强化不同视角间的匹配关系，从而为后续解码器提供更加丰富和精确的特征信息。然后将交叉注意力模块输出的特征进行连接，输入解码器（Decoder）中得到两个视角的中间图像，表示为 p^i 和 p^{i+1} 。在第三个阶段，该阶段旨在优化不同视角下图像内容的视角相关性，将两个中间图和其对应的高级语义特征相乘，并输入到交叉注意力模块中，进一步强化视角间的关系，最后输出预测的分割图像 M^i 和 M^{i+1} 。在第四个阶段，为了进一步提升反射分割的准确性，引入多视图一致性约束，将其他视角下的分割结果重映射回第 i 个视角，利用重投影误差 e_i ，优化分割结果。




图 3.3 基于多视图一致性的反射分割算法架构图

3.3.2 多视图一致性

基于第二章介绍的多视角立体理论，可以计算得到多视角下图像的相机参数。用 $\{M^i\}_{i=1}^N$ 表示 N 张多视角下分割完成的图像，基于已知的相机参数将每一个图像重映射到其他视角下，可以表示为：

$$M^{i \rightarrow j} = \text{proj}(K, T^{i \rightarrow j}, M^i), \quad (3-1)$$

其中 K 为相机的内参， T 为两幅图像之间的相对位姿矩阵， $M^{i \rightarrow j}$ 表示第 i 张掩膜图像在第 j 个视角下的重投影图像，因此可以计算 $M^{i \rightarrow j}$ 与 M^j 之间的重投影误差，最终定义每一个视角的重投影误差 e_i 为前 k 个最小跨视图投影误差的平均值，可以表示为：

$$e_i = \text{avg}(\text{TopK}(M^{j \rightarrow i} - M^i)), \quad i, j = 1 \dots N \quad (3-2)$$

3.3.3 损失函数

为了实现精确的反射分割任务，本文结合了 Lovasz-Softmax 损失^[75]和多视图一致性损失训练网络。Lovasz-Softmax 损失通过对传统的交叉熵损失进行修正，不仅关注每个像素点的分类准确度，更侧重于优化整个类别区域的 IoU 指标，因此本文选用其作为主导图像分割任务的损失项。最终的损失函数可以表示为：

$$\begin{aligned} \mathcal{L} = \sum_i^N (\ell_s(p^i, G^i) + \ell_s(M^i, G^i) + \ell_s(p^{i+1}, G^{i+1}) \\ + \ell_s(M^{i+1}, G^{i+1}) + \lambda e_i), \end{aligned} \quad (3-3)$$

其中 ℓ_h 表示应用于第 i 张图像的 Lovasz-Softmax 损失，可以帮助模型更准确地区分分割图像的前景和背景。 p^i 表示第 i 张图像生成的中间图像， G^i 表示对应的真实图像， M^i 表示第 i 张图像的预测结果， e_i 表示第 i 张图像的重投影误差。

通过这样的损失函数设计，本文的网络不仅关注单一视角下的图像分割质量，也衡量了不同视角下图像的几何结构一致性，使得反射分割任务达到更高的准确性和鲁棒性。

3.4 基于姿态估计的人体分割

在室外场景重建的研究中，人类作为最主要的非刚体对象，其存在为场景的高精度重建带来了巨大的挑战。鉴于这一难题，本文提出基于姿态估计的人体分割算法，旨在精确地分割出室外场景中存在的人类对象，为后续三维重建阶段提供高质量的数据基础。

室外场景中的人体分割面临着诸多复杂因素的困扰。首先，人类数量的不可预知和群体行为交互的复杂性，导致人体在场景中的分布和运动状态呈现出极大的不确定性。其次，光照条件的剧烈波动和背景环境的多样性，进一步加剧了人体分割任务的难度。与一般的实例分割类别不同，“人”因其特殊的生物结构特性，可以通过骨骼关键点被很好地定义。骨骼关键点不仅提供了人体的姿态信息，其连贯的运动轨迹也能直观地反映出人类的动态行为，而且骨骼关键点对服装变化、背景干扰表现出较强的鲁棒性。因此，将骨骼关键点的特征信息用于引导分割算法，有助于提升人体分割的准确度与稳定性。

鉴于以上背景，本文首先使用先进的姿态估计算法对输入图像进行预处理，精确地估计出场景中所有人的骨骼关键点位置，将其转换为易于融合的骨骼热图的形式。然后，本文设计了一种针对人体分割任务的网络架构，通过新颖的可移位交叉注意力模块，将骨骼热图特征与原始图像特征深度融合，利用骨骼关键点信息引导人体分割过程，实现对人体的精细化分割。

3.4.1 多人姿态估计

考虑到骨骼捕捉设备高昂的硬件成本，本文采用先进的姿态估计算法，从图像中直接提取 2D 骨骼关键点，作为基于姿态估计的人体分割算法的数据预处理步骤。因此姿态估计算法的性能，很大程度影响了最终的人体分割结果。2D 人体姿态估计作为计算机视觉领域的研究热点，旨在精确定位人体解剖结构上的关键点，如肘、手腕等部位。目前流行的姿态估计算法主要分为两类：自上而下^[76-79]和自下而上^[80]。鉴于本研究的应用场景为室外场景，

具有复杂的光照条件和背景干扰，对姿态估计算法的稳健性和准确性要求较高。因此，本文选择精度更优的自上而下的方法来进行姿态估计，旨在确保获得高质量的骨骼关键点信息，为基于姿态估计的人体分割算法提供良好的数据输入。

为了实现既高效又鲁棒的室外人体分割，本章采用 Fater R-CNN^[36] 人体检测器和 HRNet^[81] 姿态估计算法的组合方案，实现精确的姿态估计。尽管 HRNet 是针对单一个体的姿态估计任务提出的，但是通过与 Fater R-CNN 相结合，成功将其拓展用于实现室外场景中的多人姿态估计。为了高效融合骨骼关键点信息和原始图像信息，本文将多人姿态估计算法输出的骨骼关键点坐标转换为骨骼热图，作为本文提出的人体分割算法的输入。对于图像中出现的每一个人类对象，以其各个骨骼关键点为中心，通过高斯变换生成每个骨骼关键点的 2D 热图，可以表示为：

$$J_{kij} = e^{-\frac{(i-x_k)^2+(j-y_k)^2}{2 \times \sigma^2}} \times c_k, k = 1 \dots K, \quad (3-4)$$

其中 σ 表示高斯函数的方差， (x_k, y_k) 表示第 k 个骨骼关键点的坐标， c_k 表示第 k 个骨骼关键点的置信值， K 为骨骼关键点总数的数量。由于本文采用 HRNet 算法提取骨骼关键点，遵循 COCO (Common Objects in Context, COCO^[82]) 骨骼系统，所以 $K=17$ 。同时，本文对生成的热图进行零填充，确保其尺寸与原始图像保持一致。经过此调整，将所有人类对象的 K 个热图直接累加，无需进行额外的操作，就可以得到多人骨骼热图。这一系列步骤不仅确保了高质量的骨骼关键点信息，而且也为室外场景中的多人姿态估计任务提供了一个实用且高效的解决方案。

3.4.2 网络整体设计

面对室外场景中剧烈的光线变化、复杂的环境扰动以及高动态的人体交互，设计一种鲁棒的人体分割算法至关重要。同时，如何有效地利用姿态估计算法所提供的骨骼关键点信息，进一步提升分割精度，是人体分割算法的另一个核心挑战。鉴于此，本文提出一种双模态融合架构，引入新颖的可移

位交叉注意力模块，将丰富的姿态信息用于引导精细化的人体分割任务。




图 3.4 基于姿态估计的人体分割算法架构图

如图 3.4 所示，本文的人体分割算法将原始图像和骨骼热图作为联合输入，以 UNet^[83]作为基础框架，旨在实现高效精确的人体分割。该网络架构主要包含 RGB 图像的编码器、骨骼热图的编码器和解码器三部分。本文使用 Swin Transformer 作为编码器和解码器的骨干网络，包含四个阶段，旨在逐步提取输入图像的多层次特征，提高模型提取多尺度特征的能力。在前两个阶段，遵循 Swin Transformer 的原始架构。首先，将输入图像划分为若干个非重叠的小块，在实验中设置每个小块的大小为 4×4 ，因此每个小块特

征的维数为 $4 \times 4 \times 3 = 48$ 。这些小块经过线性嵌入层（Patch Embedding）转换为 C 维向量，然后输入 Swin Transformer 基础模块中进行编码，通过自注意力机制捕获图像内在的依赖关系。在后面两个阶段，本文对 Swin Transformer 基础模块进行改进，将其中的移动自注意力模块替换为本文提出的可移位交叉注意力模块，以增强 RGB 图像和骨骼热图的信息融合，同时保留其原有的局部窗口注意力模块，以保持对自身内在特征的建模能力。为了构建层次化的特征表示，对每个阶段的输入数据采取如下策略：每个分块与其周围 2×2 的邻接分块进行连接，从而将分块数量减少至原来的四分之一。这一操作导致特征图的分辨率在各个阶段分别为 $\frac{H}{4} \times \frac{H}{4}$ 、 $\frac{H}{8} \times \frac{H}{8}$ 、 $\frac{H}{16} \times \frac{H}{16}$ 和 $\frac{H}{32} \times \frac{H}{32}$ ，具有与典型卷积网络^[84, 85]相同的特征图分辨率。同时，本文将每个线性嵌入层的输出维度相应地调整为 C 、 $2C$ 、 $4C$ 、 $8C$ 。最后，经过深度融合的多模态特征通过解码器进行逐层上采样，同时不断融合来自编码器的语义特征，最终获取精细化的人体分割结果。

3.4.3 可移位交叉注意力模块

Swin Transformer 凭借其创新的滑动自注意力模块，显著降低了 ViT 的计算成本，同时成功实现了相邻分块之间的信息融合，从而增强了全局信息建模的能力。然而，其自注意力分布仍存在一定的稀疏性，导致在一定程度上限制了模型建模长范围依赖关系的能力。针对此问题，Xia 等人^[86]提出的 Deformable Attention Transformer，通过添加偏移网络学习多个可移位采样点，以数据相关的方式选取自注意力机制中的 K 和 V 矩阵，使得注意力模块能够更关注图像中感兴趣的区域，高效捕捉更重要的信息。受到他们工作的启发，本文在模型的后两个阶段使用偏移网络学习出特征图中重要的区域。实现对信息建模过程的定向引导。

此外，由于本文的目标要实现 RGB 图像和骨骼热图的双分支融合，构建他们内在的依赖关系，因此本文提出的可移位交叉注意力模块使用骨骼热图的查询矩阵 Q 引导 RGB 图像的建模过程，使 RGB 图像更关注人体区域，

有效抑制无关信息的干扰。图 3.5 展示了本文的可移位交叉注意力模块架构图，RGB 图像和骨骼图像的可移位交叉注意力模块可以表示为以下形式：

$$q_i, k_i, v_i = f_i(W_{qi}, W_{ki}, W_{vi}), i \in \{1, 2\}, \quad (3-5)$$

$$z_1 = \text{softmax}(q_2 * k_1^T / \sqrt{d}) * v_1, \quad (3-6)$$

$$z_2 = \text{softmax}(q_2 * k_2^T / \sqrt{d}) * v_2, \quad (3-7)$$

其中，RGB 图像和骨骼图像特定网络分支的向量分别用下标 1 和 2 表示。对于骨骼图像网络分支而言，其注意力结果由自身的查询、键和值计算得到，而 RGB 图像分支的查询由骨骼图像的分支提供，这种交叉的注意力运算有助于更好的融合这两个不同分支的信息。




图 3.5 可移位交叉注意力模块架构图

3.5 实验与分析

3.5.1 实验设置

本章的实验均在一台 Intel(R) Core(TM) i7-11700KF @ 3.60GH 处理器和 NVIDIA GeForce RTX 3080 Ti 显卡的主机上运行，搭载 Window 11 和 Ubuntu 20.04.4 LTS 双系统。实验环境主要由 PyCharm 集成开发环境、Python 3.7.12 运行环境、RealityCapture 1.2 软件和 COLMAP 工具组成。

在反射分割实验中，本文在基于 PyTorch^[87] 1.13 和 CUDA 11.7 实现基于多视图一致性的反射分割算法，使用在 ImageNet^[88]上训练好的预训练模型 ResNext-101 作为骨干网络提取图像特征，COLMAP 计算相机位姿用于计算重投影误差。在模型训练期间，设置初始学习率为 0.0001，并采用余弦退火的策略逐步调整学习率，以优化训练过程。此外，设置批大小为 8，训练轮次为 15。

在人体分割实验中，本文基于 PyTorch 1.13 和 CUDA 11.7 实现基于姿态估计的人体分割算法，使用 MMSegmentation^[89]的开源工具包辅助开发过程。在数据预处理期间，本文使用在 COCO 数据集训练好的 Faster R-CNN 模型和 HRNet-W32 模型获取骨骼关键点的坐标。在人体分割模型训练期间，本文将输入图像的分辨率设置为 $224 \times 224 \times 3$ ，C 设置为 96，批大小设置为 8，学习率设置为 0.0005。

在三维重建实验中，本文首先使用 COLMAP 工具进行稀疏重建，对其特征匹配阶段的结果进行展示。然后，使用 RealityCapture 1.2 软件实现完整的三维重建流程，对最终的三维重建模型进行细节展示，以验证所提算法的有效性。

3.5.2 反射分割实验

在反射分割实验中，本文主要使用了两个数据集：视频镜面检测数据集（Video Mirror Detection Dataset, VMD-D^[71]）用于反射分割模型的训练与

测试，以及自定义数据集用于反射分割模型的测试。

VMD-D 是一个大规模的视频镜面检测数据集，它包含了 269 个视频，总共有 14987 帧图像构成，将其随机分为 143 个视频（包含 7835 帧图像）作为训练集，126 个视频（包含 7152 帧图像）作为测试集，通过详细的手工标注实现像素级的镜像掩模图像。这些图像使用智能手机收集，拥有较高分辨率（如 1920×1080 ），覆盖了各种日常生活场景，保证了数据集的多样性和泛化能力，为镜面检测任务的训练和评估提供了有效基准。

自定义数据集使用智能手机和大疆无人机“御”Mavic2 对校园内几处带有反射表面的室外场景进行拍摄，包括图书馆、体育馆、教学楼等常见室外场景，总共有 1386 张图像，分辨率大小分别为 4032×3024 、 1920×1080 。

由于目前对于反射表面分割的研究相对较少，本文将提出的反射分割算法与五种最相关的研究工作进行了对比分析，分别是专注于玻璃检测的 GlassNet^[90]、用于镜面检测的 MirrorNet^[91]、PMDNet^[74]、VCNet^[92]、VMDNet^[71]。本文使用 VMD-D 数据集对上述方法进行了训练和测试。

为了定量评估各个模型的性能，本文选用了四个被广泛接受和使用的评价指标，包括交并比（Intersection over Union, IoU）、平均像素准确率（Accuracy）、F-measure（ F_β ）及平均绝对值误差（Mean Absolute Error, MAE），这些指标为模型准确性提供了全面的评估。交并比的计算公式可以表示为：

$$IoU = \frac{|A \cap B|}{|A \cup B|}, \quad (3-8)$$

其中 A 为预测区域，B 为真实标注区域。平均像素准确率的计算公式可以表示为：

$$Accuracy = \frac{N_c}{N}, \quad (3-9)$$

其中 N 为像素个数， N_c 为正确分类的像素个数。 F_β 的计算公式可以表示为：

$$F_{\beta} = 2 \times \frac{Precision \times Recall}{Precision + Recall}, \quad (3-10)$$

其中 $Precision$ 为准确率， $Recall$ 为召回率。平均绝对值误差的计算公式可以表示为：

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \bar{y}_i|, \quad (3-11)$$

其中 y 为真实值， $\bar{y}$ 为预测值。

表 3.1 展示了这些方法的定量对比结果。从中可以看出，本文提出的方法在所有评价指标上均表现最佳。这一结果表明本文的方法在反射分割任务上具有较高的准确性和有效性。

为了验证本文提出的反射分割算法在室外场景重建数据集下的有效性，本文将其应用于自定义数据集，进行可视化结果对比。图 3.6 直观地展示了本文提出的反射分割算法在自定义数据集上的表现。从图中可以看出，本文的方法可以有效识别出图像中的反射表面，尽管在分割细节方面与真实的标注图像存在一些差距，但是该方法也取得了优秀的反射分割结果，为后续的三维重建流程提供了良好的数据基础。

表 3.1 反射分割算法的性能对比

方法	IoU ↑	Accuracy ↑	F_{β} ↑	MAE ↓
GlassNet	0.552	0.864	0.718	0.137
MirrorNet	0.505	0.864	0.681	0.145
PMDNet	0.532	0.872	0.749	0.128
VCNet	0.539	0.877	0.749	0.123
VMDNet	0.567	0.895	0.787	0.105
本章方法	0.573	0.902	0.792	0.101




图 3.6 基于多视图一致性的反射分割算法结果展示

3.5.3 人体分割实验

在人体分割实验中，本文主要使用了两个数据集：COCO 数据集用于人体分割模型的训练与测试，以及上一节相同的自定义数据集用于展示所提算法的有效性。

COCO 是一个规模庞大且极具影响力的视觉数据集，为图像检测、语义分割等多种视觉任务专门设计，被广泛应用于计算机视觉领域的研究。因其广泛的覆盖范围、详尽的标注信息，常被用于训练和评估最先进的对象检测和分割模型。该数据集有 330k 张图像，其中 220k 张带有详细标注，包含 150 万个目标实例，80 种不同对象类别。因为本文的研究目标针对“人”这一特定类别，因此本章的实验在 COCO 的人物类别的子集上进行。该子集包含了人物在日常生活中的各类场景，包括常见的室外场景，与本文的任务目标十分匹配。同时，该数据集还对人体 2D 关键点进行了详细标注，为评

估本文使用的姿态估计方案提供了现成的基准，从而全面评估本文提出的基于姿态估计的人体分割算法。

表 3.2 人体分割算法的性能对比

方法	骨骼点真值	平均精度
Mask R-CNN	×	0.532
Pose2Seg	×	0.555
Pose2Seg	√	0.582
本章方法	×	0.564
本章方法	√	0.577

表 3.2 展示了本文方法与实例分割算法 Mask R-CNN 和最近相关工作 Pose2Seg 的对比结果。在实验过程中，本文使用官方代码和配置文件，对其进行重新训练。同时，使用 COCO Person 数据集中的训练集对所有模型进行充分训练，使用其验证集测试所有模型的性能，以公平地评估所有方法。为了全面评估本文所使用的姿态估计方案以及人体分割模型，本文分别选取 COCO Person 数据集中的骨骼点真值，以及本文提出的 Faster R-CNN+HRNet 姿态估计方案输出的骨骼点信息作为输入数据，评估模型的平均准确率。遵循同样的策略，本文对 Pose2Seg 进行了评估。实验结果表示，尽管在使用骨骼点真实值作为输入时，本文的模型准确度稍低于 Pose2Seg，但是当结合提出的姿态估计算法验证整个算法框架时，本文的算法取得了最优值。

为了展示本文的人体分割算法对室外场景重建数据集的有效性，本文将应用于自定义数据集。图 3.7 展示了基于姿态估计的人体分割算法在自定义数据集上的表现。从图中可以看出，本文的方法可以准确识别出人体轮廓和主要身体部位，尽管在微小细节方面还有待提升，但是该方法在整体上取得了优秀的分割性能，有效地缓解人类存在对室外场景重建算法的不良影响。



图 3.7 基于姿态估计的人体分割算法展示

3.5.4 三维重建实验

本文基于前两节的图像分割算法对输入图像进行精心的预处理，可以去除室外场景中的反射和人类两大干扰因素对传统重建算法中的特征匹配阶段的不良影响，同时可以计算得到更加精确的相机参数。为了验证本章提出分割算法显著提升了稀疏重建过程中特征匹配阶段的精确度，本文使用 COLMAP^[4]工具对此进行单独验证。COLMAP 是一个用于三维重建的开源项目，常被用于三维重建领域的学术研究。它不仅支持用户随意地查看和修改源代码，还提供图形用户界面（GUI）和命令行界面（CLI），允许用户输入多视角图像，执行稀疏重建、稠密重建的完整流程，但是它不包括模型的后处理功能。此外，为了验证本文提出的图像分割算法对传统多视图重建

算法的有效性，将稀疏重建阶段计算得到的相机参数作为输入，通过稠密重建算法最终得到密集的点云模型。为了进一步实现对三维模型的可视化展示，本文使用 RealityCapture^[93]进行三维重建结果的可视化展示。RealityCapture 是一款专业级的摄影测量软件，被广泛用于游戏开发、电影制作和建筑可视化等领域。这款软件不仅集成了基础的三维重建功能，还配备了一整套的可视化工具，包括纹理映射、模型编辑、精细化处理等高级处理技术，为用户提供了一个高度直观、操作便捷的工作平台。




图 3.8 特征匹配的对比结果展示

图 3.8 展示了应用反射分割算法前后，传统算法特征匹配阶段的结果对比。从结果中可以明显观察到，在未使用反射分割算法时，反射表面产生了大量的错误特征匹配。然而，经过反射分割算法进行预处理之后，显著提高了图像特征匹配的精度，有效消除了反射纹理对三维重建过程的干扰。




图 3.9 三维模型的对比结果展示

图 3.9 展示了在自定义数据集上应用反射分割算法前后，最后的三维重建模型对比。从图中可以明显看出，经过反射分割算法预处理后得到的三维模型在完整性和平滑度上得到了显著提升。具体来说，场景一中红色标出的区域，因反射效应导致严重的形状扭曲。经过反射分割处理后，这一缺陷被有效修正，得到的模型不仅更加完整，其反射表面的深度也更真实地反映了实际场景。场景二中的玻璃窗框受到反射纹理的不利影响，导致重建的形状出现弯曲，且玻璃表面也不够平滑。通过应用反射分割算法之后，这些问题得到明显改善，窗框结构更加直正，玻璃表面更加平整。场景三中的原始模型存在严重扭曲，且整体模型不够完整。经过反射算法处理后得到的三维模型明显更加完整，形状扭曲也得到了改善。

实验结果表明，本文提出的图像分割算法，有效提高了室外场景的三维重建精度，使得重建结果更加真实和可靠，这种方法为解决复杂室外场景下的三维重建问题提供了一种新的有效途径。其中两个核心算法：基于多视图的反射分割算法成功实现了室外场景中的反射面分割，有效克服了室外场景中反射纹理对特征匹配的影响；基于姿态估计的人体分割算法也成功将人体分割出来，消除了人体对于室外场景重建的干扰，提高了三维重建的精度和可靠性。

3.6 本章小结

本章首先探讨了传统的多视图重建算法在处理室外场景中存在的反射表面、动态人体时遇到的挑战，然后系统概述了本章提出的基于图像分割的室外场景重建算法，并对其中两个核心算法的任务目标、算法理论以及网络架构设计等进行了详细阐述。其中，基于多视图一致性的反射分割算法将多视图一致性约束引入基于深度学习的分割算法中，并结合精心设计的网络架构，成功分割出图像中反射区域；基于姿态估计的人体检测算法结合姿态信息与图像信息，并结合有效的双模态网络结构，实现了在复杂的室外场景中优秀的人体分割结果。为了验证本章所提算法的有效性，本章进行了一系列

对比实验，并进行了可视化展示。实验结果表明，本文提出的反射分割算法和人体分割算法均具有优秀的分割性能。同时，将这两个算法应用于三维重建算法中，有效提高了重建模型的精度和整体质量。

第4章 基于神经辐射场的室外场景重建

4.1 引言

近年来,神经辐射场作为一种全新的三维表达方式,以其逼真的视图合成效果,在三维重建领域引起了广泛的关注与研究。然而,尽管神经辐射场在诸多方面展现出巨大的潜力,但是将其应用于室外场景重建任务时,存在一些局限性。首先,神经辐射场因其固有的几何辐射歧义性^[94],在建模过程中倾向于将场景建模为半透明状的“薄雾”,导致对场景的几何建模精度较低。而室外场景多变的光照变化、复杂的场景几何以及建筑物表面强烈的反射纹理,进一步加剧了这种几何模糊性。如图 4.1 所示,当尝试使用神经辐射场对校园某处场景进行建模时,其渲染效果和深度估计的结果均出现了明显的误差,直观地反映出神经辐射场在处理复杂室外场景时的局限性。同时,神经辐射场只能处理简单的高光反射,难以应对室外场景中复杂的反射与透射表面。具体来说,神经辐射场往往会将反射表面反射出的虚像错误地建模为反射表面内部的真实场景,无法准确识别反射表面的存在,导致错误地估计场景深度,进而最终重建失败。此外,由于室外场景的复杂性和动态性,反射表面在不同视角下呈现的反射内容会发生高频变化,这对神经辐射场在反射纹理渲染方面也提出了挑战。

鉴于以上背景,本文提出基于神经辐射场的室外场景重建算法,旨在解决神经辐射场在处理室外复杂场景时的局限性,力求在提高室外场景重建精度的同时,并实现对反射纹理的逼真渲染效果。

本章将详细介绍本文提出的基于神经辐射场的室外场景重建方法。4.2 概述了该算法的总体框架;4.3 介绍了基于多视图立体的漫反射场景重建算法的设计与实现;4.4 介绍了基于分块解耦的反射场景重建算法的设计与实现;4.5 通过实验验证与分析,证明所提算法的有效性。



图 4.1 神经辐射场的室外场景重建结果

4.2 算法框架

随着现代建筑广泛采用大面积、强反射特性的材质作为其外表面，复杂多变的反射纹理已成为室外场景中的普遍现象，对神经辐射场的场景建模能力提出了巨大挑战。Tancik 等人^[46]在应对大型环境重建难题时，将环境划分为多个块，并使用单独的神经辐射场对其进行建模，以增强对复杂场景的建模能力。最近他们工作的启发，为了精确构建带有复杂反射现象的室外场景，本文将室外场景划分为漫反射场景和反射场景，利用特定的优化算法进行分开建模，最终实现优秀的重建结果和渲染效果。

如图 4.2 所示，针对室外场景中的漫反射场景，本文采用传统的多视图立体算法得到深度先验，指导优化神经辐射场学习出正确的场景几何，可以有效解决神经辐射场在几何重建中的模糊性问题，显著提高了漫反射场景重建的精度。这一改进不仅增强了神经辐射场对大规模、低反射率场景的建模能力，更为后续反射场景重建提供重要的场景先验信息。针对反射场景，本

文提出一种反射与透射解耦的算法架构，利用已有的场景先验和精心设计的损失函数，将反射纹理与透射场景成功解耦，实现了神经辐射场对复杂反射的准确建模。最后，本文基于分块渲染的思想，将不共面的反射场景使用单独的神经辐射场进行渲染，能够精确拟合出每一个反射表面高频变换的微小细节，最终实现对室外场景的高精度重建以及逼真的反射渲染效果。




图 4.2 基于神经辐射场的室外场景重建方法框架图

4.3 基于多视图立体的漫反射场景重建

神经辐射场技术在场景渲染方面展现出了令人印象深刻的效果，但是其内在的形状辐射歧义性问题限制了对复杂几何形状的建模能力，尤其是在诸如墙面等弱纹理的室外场景。这种几何模糊性会导致神经辐射场在推断场景几何深度时产生偏差，进而影响到三维重建的准确性。传统的多视图重建技术在几何建模方面却显示出更高的精确性，通过将其几何先验引入神经辐射场的框架中，可以充分发挥两者优势，实现互补。这种融合方式不仅能够保持神经辐射场的渲染能力，而且提高了场景的几何正确性。因此，本文提出基于多视图立体的漫反射场景重建算法，利用上一章提出的基于图像分割的

室外场景重建算法作为前置步骤，得到较为精确的场景深度信息，引导神经辐射场的学习过程，从而学习出更加精确的漫反射场景几何，避免形状辐射歧义性的问题。

4.3.1 网络整体设计

如图 4.3 所示，本文的方法将多视图立体技术引入神经辐射场的训练流程中，实现更准确的漫反射场景重建。首先，本文利用先进的图像分割算法，处理多视角图像得到相应的掩膜图像，确保只有漫反射场景被保留下来，作为本文的重建对象。其次，本文利用得到的带掩膜的多视角图像，对其应用传统的多视图立体算法，生成每个视角下的深度图。最后，本文将得到的深度图作为深度先验，优化神经辐射场的训练过程，从而实现更为精确的场景重建。经过这样的设计，神经辐射场不仅能够准确地捕获场景的几何细节，而且能够充分发挥其强大的视图合成能力，实现更为真实的渲染效果。




图 4.3 基于多视图立体的漫反射场景重建算法架构图

4.3.2 损失函数

基于第二章介绍的神经辐射场的相关理论，通过对光线上的点进行积分得到每个像素的颜色值，同理，可以通过积分这些点求得图像中每个像素的深度值，经过近似离散化后可以表示为：

$$D(r) = \sum_{i=1}^N T_i \left(-\exp(-\sigma_i \delta_i) \right) t_i \quad (4-1)$$

本文将得到的深度图引导神经辐射场的训练过程，并且保留了原始神经辐射场的光度一致性损失。因此，最终的损失函数可以表示为：

$$\mathcal{L} = \sum_{r \in \mathcal{R}} [\|\hat{C}(r) - C(r)\|_2^2 + \lambda_d \|\hat{D}(r) - D(r)\|_2^2], \quad (4-2)$$

其中， $\hat{C}(r)$ 表示渲染的颜色， $C(r)$ 表示真实像素的颜色， $\hat{D}(r)$ 表示渲染的深度， $D(r)$ 表示真实图像的深度， λ_d 表示超参。通过利用光度一致性和深度一致性的联合训练策略，在每一次的网络迭代更新中，神经辐射场既考虑了颜色信息，又考虑了几何结构，使其适应于室外场景重建任务中。

4.4 基于分块解耦的反射场景重建

在神经辐射场的原始工作中，尽管作者引入位置编码帮助多层感知机学习高频特征，提高场景的渲染质量，但是这种策略仅能处理简单的反射效应，如高光，对于更为复杂的光学现象，如镜面、玻璃这类材质的复杂反射时则会失效。这一挑战在渲染如摩天大楼玻璃幕墙这样复杂的室外场景时尤其明显，因为这些场景中的反射表面具有不同的法向量和多样化的材质特征，随着视点变化时，会呈现出丰富且复杂的反射模式。

为了精准捕捉这种高频变化，本文提出一种新颖的解耦策略，将带有反射表面的场景分解为透射场景和反射纹理。透射场景表示真实场景的几何结构，反射纹理则表示反射表面的纹理图案。通过这种方法，可以正确估计出反射场景的深度，有效地克服了传统神经辐射场在处理反射内容时，将其错

误地建模为镜面内外的几何结构的问题，同时成功渲染出逼真的反射纹理。对于场景中非共面的反射表面，本文进一步采用分块渲染的策略，对场景中每个近似平面的反射面使用单独的神经辐射场进行建模，通过这种方式，每个分块特定的神经辐射场能够专注于模拟该区域内的光线行为和细节变化，从而更加正确地渲染出复杂的反射效果，并极大地提升了整个室外场景渲染的真实感。

4.4.1 反射解耦

在计算机视觉领域，将输入图像表示为不同成分相加是一种常见的方法，Guo 等人^[95]提出将整个场景分解成透射场景和反射场景两个组件分别进行建模，在反射场景渲染的任务上取得了优秀的渲染效果。但是该方法的解耦方式是高度不受约束的，很容易陷入局部最优值，特别是处理复杂的室外场景时，很难将整个场景成功分解。受到他们工作的启发，本文采取与他们相似的公式，将输入图像 I 表示为：

$$I = I_t + \beta I_r, \quad (4-3)$$

其中， I_t 表示透射场景， I_r 表示反射纹理， β 表示每个像素的合成反射率。




图 4.4 反射解耦算法架构图

如图 4.4 所示，本文修改神经辐射场的网络架构以适应本文提出的反射解耦算法。网络的输入是反射场景中的三维点坐标 (x, y, z) 。考虑到在实际生活中，不同材质的物体具有不同的反射率，即反射率与透射场景相关，因此

本文在网络结构设计上，增加透射场景的神经辐射场输出，不仅包括透射场景三维点的颜色值 $\mathbf{c}^t$ 和密度值 σ^t ，还同时输出反射率 α 。而反射纹理的神经辐射场仅输出密度值 σ^r 和颜色值 $\mathbf{c}^r$ 。此外，本文保留了原始神经辐射场的设计，将方向向量 (θ, φ) 作为输入，影响透射场景颜色的合成，这样可以模拟透射场景中的高光效果，而复杂的反射纹理则由反射神经辐射场单独负责建模。

基于第二章介绍的神经辐射场的相关理论，通过沿光线路径对各点的反射率进行积分，最终每个像素的合成反射率 β 可以表示为：

$$\beta(r) = \sum_{i=1}^N T_i(\sigma^t)(1 - \exp(-\sigma_i^t \delta_i))\alpha_i \quad (4-4)$$

因此，图像最终的渲染颜色可以表示为：

$$\hat{\mathbf{C}}(r) = \hat{\mathbf{C}}(r; \sigma^t, \mathbf{c}^t) + \beta(r)\hat{\mathbf{C}}(r; \sigma^r, \mathbf{c}^r) \quad (4-5)$$

由于直接将整个反射场景进行解耦的过程是高度不受限的，本文对透射场景的深度和反射纹理的深度进行约束，以实现成功解耦。对于透射场景的部分，本文利用上一节求得的漫反射场景深度对其深度进行监督。因此，透射场景的深度损失可以表示为：

$$\mathcal{L}_t = \sum_{r \in \mathcal{R}} \|\hat{D}_t(r) - D_t(r)\|_2^2 \quad (4-6)$$

对于反射纹理的部分，为了将其成功解耦，本文倾向于将其建模为纹理薄膜的几何形状。因此本文采用了双向深度一致性损失，对反射纹理的成功建模。首先本文定义了一个反向深度 $\overleftarrow{D}_r(r)$ ，与正常反射纹理深度 $D_r(r)$ 的计算不同，它从相机发出的光线 r 反方向进行积分，可以表示为：

$$\overleftarrow{D}_r(r) = \sum_{i=1}^N \overleftarrow{T}_i(-\exp(-\sigma_i \delta_i))t_i \quad (4-7)$$

$$\overleftarrow{T}_i = \exp(-\sum_{j>i} \sigma_j \delta_j) \quad (4-8)$$

最后，本文的双向深度一致性损失则可以表示为：

$$\mathcal{L}_r = \sum_{r \in \mathcal{R}} \|\bar{D}_r(r) - D_r(r)\|_2^2 \quad (4-9)$$

因此，最终的损失函数为光度一致性损失、深度损失、双向深度一致性损失的加权和，可以表示为：

$$\mathcal{L} = \mathcal{L}_c + \lambda_t \mathcal{L}_t + \lambda_r \mathcal{L}_r \quad (4-10)$$

本文对室外场景中带有反射表面的区域应用基于神经辐射场的解耦算法，并结合精心设计的深度约束，最终成功地将透射场景与反射纹理分解，并实现了高质量的视图渲染效果。

4.4.2 分块渲染

在复杂的室外场景中，常常包含多个不共面的反射面，这些表面的反射特征随着材质、结构、光照变化等因素而不同，使用单一的神经辐射场很难捕捉场景中所有复杂的反射变化。为了应对这一挑战，本文提出了一种分块渲染的策略。首先，可以利用上一章提出的反射分割算法确定场景中各个近似平面的反射区域，在一些特别复杂的情况下，可能需要人工标注来辅助算法，确保反射区域的准确划分。在确定了反射区域后，为每个区域单独构建一个神经辐射场，以学习特定的光照和反射特性。由于每个模型专注于学习一个相对简单的局部特征，因此能够捕捉到非常精确的细节和光照变化，使得每个反射面的渲染都高度真实。最后，将所有反射面重新映射回整个场景中，最终可以得到一个整体上高度真实感的渲染图像。

4.5 实验与分析

4.5.1 实验设置

本章的实验均在一台 Intel(R) Core(TM) i7-11700KF @ 3.60GH 处理器和 NVIDIA GeForce RTX 3080 Ti 显卡的主机上运行，主机的操作系统 Ubuntu

20.04.4 LTS。主要的实验环境由 Pycharm 集成开发环境和 Anaconda 虚拟环境组成，为代码的编写和测试提供了便捷的平台，同时基于 PyTorch 1.13 和 CUDA 12.0 实现本章提出的算法，充分利用硬件的计算能力。

在基于多视图立体的漫反射场景重建算法的实验设置中，本文使用 COLMAP 工具获取深度先验，并对输入图像进行下采样操作，采样因子为 2，批大小设置为 1024，每根光线上的采样点数量为 64，超参 λ_d 设置为 0.1，初始学习率设置为 0.0005。

在基于分块解耦的反射场景重建算法的实验设置中，本文同样对输入图像进行下采样操作，采样因子为 2，批大小为 128，每条光线上的采样点数量为 64。为了防止实验结果陷入局部最优值，本文采用等间隔调整策略调整超参，对于 λ_r ，本文在前 10 轮迭代中将其设置为 0.05，之后设置为 0.0001，对于 λ_t ，本文在前 1000 轮迭代中设置为 0.1，之后设置为 0.01。

4.5.2 数据集

由于缺乏包含复杂反射效应的室外场景数据集，本章采用上一章介绍的自定义数据集验证所提算法的有效性。首先在数据集的预处理步骤中，使用 COLMAP 获取多视角图像的相机参数，计算出相机光线的方向向量，这是训练神经辐射场的前提条件。然后利用上一章的反射分割算法，分割出图像中的反射场景，对于一些非常复杂的场景，本文进一步使用 LableMe 标注工具来手动优化分割结果。

4.5.3 实验结果与分析

为了验证本文提出的基于多视图立体的漫反射场景重建算法的有效性，本文首先使用图像分割算法对输入图像进行预处理，然后分别应用本文提出的算法与原始 NeRF 算法，每种方法使用相同的渲染方程生成渲染图和深度图进行对比。图 4.5 展示了对比结果，从渲染图中可以看出，本文的算法显著提升了场景渲染的真实性和精确度，例如台阶的边缘、墙壁的纹理以及植物叶片的质感等微小细节被成功渲染出来，而原始 NeRF 算法输出的渲染图

虽然整体上还原了场景的原貌，但是细节非常模糊。同时，本文的算法在深度估计方面也有显著优势。与原始 NeRF 输出的深度图相比，本文的算法在保持整体深度分布合理的同时，呈现出更高精度的细节，准确地反映出了场景的三维几何结构。




图 4.5 基于多视图立体的漫反射场景算法结果对比展示

为了验证本文提出的反射解耦算法的有效性，本文对自定义数据集中的某个场景应用了本文的算法，图 4.6 直观地展示了本文的算法结果。为了更清晰地展示出本文算法的解耦性能，本文分别展示了最终的合成图像、透射场景的渲染图、透射场景的深度图、反射纹理的渲染图、反射场景的深度图以及反射率分布图。结果表明，本文提出的反射解耦算法可以有效地将透射场景与反射纹理分离。从透射场景的深度图可以看出，本文的算法可以准确估计出场景深度。从反射率分布图可以看出，本文的算法可以正确识别反射表面的存在。尽管在解耦的精度方面，本文的算法仍有提升空间，但是整体

上证实了本文算法的有效性。




图 4.6 反射解耦算法结果展示

为了验证本文提出的分块解耦算法的有效性，本文对自定义数据集中的某处反射场景应用本文的算法，与原始 NeRF 的渲染结果进行对比，图 4.7 展示了对比结果。从图中可以看出，本文的分块解耦算法在图像渲染方面展现出显著优势，成功复现出反射表面的纹理细节和环境的光照变化，而原始 NeRF 的渲染结果则丢失了大量纹理细节，整体效果不佳。




图 4.7 分块解耦算法结果对比展示

为了定量评估本文的分块解耦算法，本文选用了三个广泛采用的指标：峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）、结构相似性（Structural Similarity Index Measure, SSIM）及感知图像质量评估（Learned Perceptual Image Patch Similarity, LPIPS），与原始的 NeRF 及其一个变体 NeRFReN[95] 进行对比。NeRFReF 在 NeRF 的基础上实现了对反射场景建模，与本文的研究十分相关。表 4.1 展示了对比结果，从中可以看出，本文的分块解耦算法有效地提升了神经辐射场在复杂反射场景下的建模能力。

表 4.1 分块解耦算法的性能对比

方法	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
NeRF	35.869	0.972	0.018
NeRFReN	36.268	0.968	0.027
本章方法	37.971	0.993	0.007

图 4.8 展示了本文的分块解耦算法在三维重建方面的结果。本文对自定义数据集中的某处反射场景进行重建，从多个任意视角对重建结果进行渲染。从结果可以看出，尽管原始输入图像并未包含这些视角，但是本文的分块解耦算法依然成功地建模出了反射场景，并且渲染出了反射表面的纹理变化。




图 4.8 三维重建结果

4.6 本章小结

本章首先探讨了神经辐射场在应对复杂室外场景重建时面临的挑战，然后系统概述了本文提出的基于神经辐射场的室外场景重建算法，并对其核心算法理论、网络设计等进行详细阐述。该算法主要包含两方面创新：基于多视图立体的漫反射场景重建算法利用多视图立体深度信息，引导神经辐射场学习出正确的漫反射场景几何，有效解决几何模糊性问题；基于分块解耦的反射场景重建算法利用精心设计的解耦策略和分块策略，将反射纹理与透射场景成功解耦，实现了神经辐射场对复杂反射的准确建模以及逼真的反射渲染。通过一系列对比实验与可视化展示，验证了本文提出的算法有效优化了现有神经辐射场技术的不足，成功将其应用于室外场景重建任务。

第5章 总结与展望

5.1 总结

室外场景重建作为计算机视觉、摄影测量以及计算机图形学等领域的重要课题，对游戏开发、影视制作、虚拟现实/增强现实等应用至关重要。随着图像理解技术的不断进步，基于多视图的三维重建算法引起了研究人员的广泛关注，并且在简单场景重建任务中展现出优秀的性能。然而，当面临复杂的室外场景重建任务时，传统的多视图重建算法往往表现不佳。主要的两个挑战来自室外场景中普遍存在的反射现象和频繁出现的动态非刚体对象，严重干扰了传统算法的正常运作，最终导致重建失败。为了解决以上难题，本文提出了基于图像分割的室外场景重建算法和基于神经辐射场的室外场景重建算法，旨在弥补现有技术在应对复杂反射及动态非刚体对象时的不足。本文的主要成果如下：

（1）本文提出基于图像分割的室外场景重建算法，将图像分割技术作为预处理步骤融入传统的多视图重建算法流程中，有效地消除了室外场景中反射现象与人类对象对传统方法中特征匹配阶段的干扰。具体来说，本文提出基于多视图一致性的反射分割算法，将多视图一致性约束与基于学习的反射分割算法相结合，并结合精心设计的网络架构，深入探索多视角图像间的空间对应关系，以提升反射分割的精度。同时，本文提出基于姿态估计的人体分割算法，将人体姿态的先验知识用于引导人体分割的过程，结合有效的网络架构，充分融合姿态线索与图像特征，以提高人体分割的精度。为了验证这两个图像分割算法的有效性，本文分别进行了反射分割实验、人体分割实验以及完整的三维重建实验。实验结果表明，本文提出的算法显著提高了室外场景重建的精度。

（2）本文提出基于神经辐射场的室外场景重建算法，针对现有神经辐

射场技术的不足进行优化与扩展，使其适应于复杂的室外场景重建任务中。针对神经辐射场固有的几何模糊性问题，本文提出基于多视图立体的漫反射场景重建算法，引入多视图立体深度信息作为约束，引导神经辐射场的学习与优化过程，正确学习出漫反射场景的几何结构，从而提高室外场景的重建精度。同时，为了增强神经辐射场对复杂反射现象的建模能力，本文提出了基于分块解耦的反射场景重建算法，利用精心设计的解耦策略，将反射纹理与透射场景成功分离，不仅正确估计出了反射表面的深度，还提高了反射渲染的质量。为了进一步提升反射渲染的效果，本文对场景中非共面的反射表面使用神经辐射场进行单独建模，有效提高了整体的渲染质量。

5.2 展望

针对室外场景重建任务中诸多复杂的挑战，本文提出了基于图像分割与基于神经辐射场的两种重建算法。尽管实验结果表明，本文提出的算法在提高室外场景重建精度与渲染效果方面表现出优秀的性能，但仍存在若干潜在的局限性和改进方向值得进一步探索。

（1）目前针对室外反射场景重建的研究相对较少，高质量、大规模数据集的缺乏成为阻碍该领域发展的关键因素。尽管现有一些优质的二维图像数据集，这些数据集包含了反射现象，并已被用于执行反射分割任务，但三维数据集的稀缺性极大地限制了反射场景重建算法的研究与发展。因此，未来研究应致力于构建包含三维信息的室外反射场景重建数据集，以提高室外反射场景重建算法的性能。

（2）本文提出的分块渲染策略对室外场景中的不共面反射区域使用单独神经辐射场进行建模，成功提高了神经辐射场对复杂反射的建模能力。但是，在将不共面的反射区域重映射回反射场景的过程中会产生一定程度的误差，同时，将反射场景与漫反射场景相融合的过程中，也会出现渲染的误差，对最终的渲染效果产生了不良影响，因此需要进一步的优化算法细致调整不共面反射区域与整个场景之间的结合，以确保渲染的连贯性和真实感。

(3) 虽然本文对现有神经辐射场技术进行了优化,但如何将生成的神经辐射场有效地转化为可编辑、可细化的三维模型,仍是一个亟待解决的问题。因此,未来研究应着力于探索高效的转换算法,实现从神经辐射场到实体模型的无缝过渡。

参考文献

- [1] Majercik Z, Guertin J-P, Nowrouzezahrai D, et al. Dynamic diffuse global illumination with ray-traced irradiance fields[J]. *Journal of Computer Graphics Techniques*, 2019, 8(2).
- [2] Dai A, Chang A X, Savva M, et al. ScanNet: Richly-annotated 3D Reconstructions of Indoor Scenes[J]. *30th Ieee Conference on Computer Vision and Pattern Recognition (Cvpr 2017)*, 2017: 2432-2443.
- [3] Whelan T, Goesele M, Lovegrove S J, et al. Reconstructing scenes with mirror and glass surfaces[J]. *ACM Trans Graph*, 2018, 37(4): 102.
- [4] Schonberger J L, Frahm J-M. Structure-from-motion revisited[C]. *proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition*, F, 2016.
- [5] Furukawa Y, Hernández C. Multi-view stereo: A tutorial[J]. *Foundations and Trends® in Computer Graphics and Vision*, 2015, 9(1-2): 1-148.
- [6] Wang S, Clark R, Wen H, et al. Deepvo: Towards end-to-end visual odometry with deep recurrent convolutional neural networks[C]. *proceedings of the 2017 IEEE international conference on robotics and automation (ICRA)*, F, 2017. IEEE.
- [7] Tang C, Tan P. Ba-net: Dense bundle adjustment network[J]. *arXiv preprint arXiv:180604807*, 2018.
- [8] Bloesch M, Czarnowski J, Clark R, et al. Codeslam—learning a compact, optimisable representation for dense visual slam[C]. *proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition*, F, 2018.
- [9] Eigen D, Puhrsch C, Fergus R. Depth map prediction from a single image using a multi-scale deep network[J]. *Advances in Neural Information Processing Systems*, 2014, 27.
- [10] Choy C B, Xu D, Gwak J, et al. 3d-r2n2: A unified approach for single and multi-view 3d object reconstruction[C]. *proceedings of the Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part VIII 14*, F, 2016. Springer.
- [11] Fan H, Su H, Guibas L J. A point set generation network for 3d object reconstruction from a single image[C]. *proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition*, F, 2017.

- [12] Chen R, Han S, Xu J, et al. Point-based multi-view stereo network[C]. proceedings of the Proceedings of the IEEE/CVF international conference on computer vision, F, 2019.
- [13] Wang N, Zhang Y, Li Z, et al. Pixel2mesh: Generating 3d mesh models from single rgb images[C]. proceedings of the Proceedings of the European conference on computer vision (ECCV), F, 2018.
- [14] Chang A, Dai A, Funkhouser T, et al. Matterport3d: Learning from rgb-d data in indoor environments[J]. arXiv preprint arXiv:1709.06158, 2017.
- [15] Olson E. AprilTag: A robust and flexible visual fiducial system[C]. proceedings of the 2011 IEEE international conference on robotics and automation, F, 2011. IEEE.
- [16] Wan R, Shi B, Hwee T A, et al. Depth of field guided reflection removal[C]. proceedings of the 2016 IEEE International Conference on Image Processing (ICIP), F, 2016. IEEE.
- [17] Li Y, Brown M S. Single image layer separation using relative smoothness[C]. proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2014.
- [18] Levin A, Weiss Y. User assisted separation of reflections from a single image using a sparsity prior[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2007, 29(9): 1647-1654.
- [19] Shih Y, Krishnan D, Durand F, et al. Reflection removal using ghosting cues[C]. proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2015.
- [20] Käshammer P-F, Nüchter A. Mirror identification and correction of 3D point clouds[J]. The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, 2015, 40: 109-114.
- [21] Yang S-W, Wang C-C. On solving mirror reflection in lidar sensing[J]. IEEE/ASME Transactions on Mechatronics, 2010, 16(2): 255-265.
- [22] Mei H, Yang X, Wang Y, et al. Don't hit me! glass detection in real-world scenes[C]. proceedings of the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, F, 2020.
- [23] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]. proceedings of the Proceedings of the IEEE international conference on computer vision, F, 2017.
- [24] Li Y, Qi H Z, Dai J, et al. Fully Convolutional Instance-aware Semantic Segmentation[J]. 30th Ieee Conference on Computer Vision and Pattern Recognition (Cvpr 2017), 2017: 4438-4446.
- [25] Pinheiro P O, Collobert R, Dollár P. Learning to Segment Object Candidates[J]. Advances in Neural Information Processing Systems 28 (Nips 2015), 2015, 28.

-
- [26] Dai J F, He K M, Li Y, et al. Instance-Sensitive Fully Convolutional Networks[J]. Computer Vision - Eccv 2016, Pt Vi, 2016, 9910: 534-549.
 - [27] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]. proceedings of the 2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05), F, 2005. Ieee.
 - [28] Viola, Snow. Detecting pedestrians using patterns of motion and appearance[C]. proceedings of the Proceedings ninth IEEE international conference on computer vision, F, 2003. IEEE.
 - [29] Wang L, Ge L, Li R, et al. Three-stream CNNs for action recognition[J]. Pattern Recognition Letters, 2017, 92: 33-40.
 - [30] Uijlings J R, Van De Sande K E, Gevers T, et al. Selective search for object recognition[J]. International journal of computer vision, 2013, 104: 154-171.
 - [31] Fujiyoshi H, Lipton A J, Kanade T. Real-time human motion analysis by image skeletonization[J]. IEICE TRANSACTIONS on Information and Systems, 2004, 87(1): 113-120.
 - [32] Cortes C, Vapnik V. Support-vector networks[J]. Machine learning, 1995, 20: 273-297.
 - [33] Freund Y, Schapire R E. A decision-theoretic generalization of on-line learning and an application to boosting[J]. Journal of computer and system sciences, 1997, 55(1): 119-139.
 - [34] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]. proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2014.
 - [35] Girshick R. Fast r-cnn[C]. proceedings of the Proceedings of the IEEE international conference on computer vision, F, 2015.
 - [36] Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in Neural Information Processing Systems, 2015, 28.
 - [37] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]. proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2016.
 - [38] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]. proceedings of the Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14, F, 2016. Springer.
 - [39] Tripathi S, Collins M, Brown M, et al. Pose2instance: Harnessing keypoints for person instance segmentation[J]. arXiv preprint arXiv:170401152, 2017.

- [40] Papandreou G, Zhu T, Chen L-C, et al. Personlab: Person pose estimation and instance segmentation with a bottom-up, part-based, geometric embedding model[C]. proceedings of the Proceedings of the European conference on computer vision (ECCV), F, 2018.
- [41] Zhang S-H, Li R, Dong X, et al. Pose2seg: Detection free human instance segmentation[C]. proceedings of the Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, F, 2019.
- [42] Park J J, Florence P, Straub J, et al. Deepsdf: Learning continuous signed distance functions for shape representation[C]. proceedings of the Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, F, 2019.
- [43] Mescheder L, Oechsle M, Niemeyer M, et al. Occupancy networks: Learning 3d reconstruction in function space[C]. proceedings of the Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, F, 2019.
- [44] Mildenhall B, Srinivasan P P, Tancik M, et al. Nerf: Representing scenes as neural radiance fields for view synthesis[J]. Communications of the ACM, 2021, 65(1): 99-106.
- [45] Martin-Brualla R, Radwan N, Sajjadi M S, et al. Nerf in the wild: Neural radiance fields for unconstrained photo collections[C]. proceedings of the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, F, 2021.
- [46] Tancik M, Casser V, Yan X, et al. Block-nerf: Scalable large scene neural view synthesis[C]. proceedings of the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, F, 2022.
- [47] Rematas K, Liu A, Srinivasan P, et al. Urban Radiance Fields[J]. 2022 Ieee/Cvf Conference on Computer Vision and Pattern Recognition (Cvpr), 2022: 12922-12932.
- [48] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [49] Gheini M, Ren X, May J. Cross-Attention is All You Need: Adapting Pretrained Transformers for Machine Translation[J]. 2021 Conference on Empirical Methods in Natural Language Processing (Emnlp 2021), 2021: 1754-1765.
- [50] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:201011929, 2020.
- [51] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]. proceedings of the Proceedings of the IEEE/CVF international conference on computer vision, F, 2021.

-
- [52] Hartley R, Zisserman A. Multiple view geometry in computer vision [M]. Cambridge university press, 2003.
 - [53] Hartley R I. In defense of the eight-point algorithm[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1997, 19(6): 580-593.
 - [54] Fischler M A, Bolles R C. Random sample consensus: a paradigm for model fitting with applications to image analysis and automated cartography[J]. Communications of the ACM, 1981, 24(6): 381-395.
 - [55] Hartley R I, Sturm P. Triangulation[J]. Computer vision and image understanding, 1997, 68(2): 146-157.
 - [56] Cui H, Shen S, Gao W, et al. Progressive large-scale structure-from-motion with orthogonal MSTs[C]. proceedings of the 2018 International Conference on 3D Vision (3DV), F, 2018. IEEE.
 - [57] Cui H, Shen S, Gao X, et al. Batched incremental structure-from-motion[C]. proceedings of the 2017 International Conference on 3D Vision (3DV), F, 2017. IEEE.
 - [58] Snavely N, Seitz S M, Szeliski R. Modeling the world from internet photo collections[J]. International journal of computer vision, 2008, 80: 189-210.
 - [59] Moulon P, Monasse P, Marlet R. Adaptive structure from motion with a contrario model estimation[C]. proceedings of the Computer Vision-ACCV 2012: 11th Asian Conference on Computer Vision, Daejeon, Korea, November 5-9, 2012, Revised Selected Papers, Part IV 11, F, 2013. Springer.
 - [60] Wu C. Towards linear-time incremental structure from motion[C]. proceedings of the 2013 International Conference on 3D Vision-3DV 2013, F, 2013. IEEE.
 - [61] Jiang N, Cui Z, Tan P. A global linear method for camera pose registration[C]. proceedings of the Proceedings of the IEEE international conference on computer vision, F, 2013.
 - [62] Wilson K, Snavely N. Robust global translations with ldsfm[C]. proceedings of the Computer Vision-ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part III 13, F, 2014. Springer.
 - [63] Moulon P, Monasse P, Marlet R. Global fusion of relative motions for robust, accurate and scalable structure from motion[C]. proceedings of the Proceedings of the IEEE international conference on computer vision, F, 2013.
 - [64] Ozyesil O, Singer A. Robust camera location estimation by convex programming[C]. proceedings of the Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, F, 2015.

- [65] Sweeney C, Sattler T, Hollerer T, et al. Optimizing the viewing graph for structure-from-motion[C]. proceedings of the Proceedings of the IEEE international conference on computer vision, F, 2015.
- [66] Goldstein T, Hand P, Lee C, et al. Shapefit and shapekick for robust, scalable structure from motion[C]. proceedings of the Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part VII 14, F, 2016. Springer.
- [67] Zhu S, Zhang R, Zhou L, et al. Very large-scale global sfm by distributed motion averaging[C]. proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2018.
- [68] Triggs B, McLauchlan P F, Hartley R I, et al. Bundle adjustment—a modern synthesis[C]. proceedings of the Vision Algorithms: Theory and Practice: International Workshop on Vision Algorithms Corfu, Greece, September 21–22, 1999 Proceedings, F, 2000. Springer.
- [69] Kajiya J T, Von Herzen B P. Ray tracing volume densities[J]. ACM SIGGRAPH computer graphics, 1984, 18(3): 165-174.
- [70] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International journal of computer vision, 2004, 60: 91-110.
- [71] Lin J, Tan X, Lau R W. Learning to detect mirrors from videos via dual correspondences[C]. proceedings of the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, F, 2023.
- [72] Xie S N, Girshick R, Dollár P, et al. Aggregated Residual Transformations for Deep Neural Networks[J]. 30th Ieee Conference on Computer Vision and Pattern Recognition (Cvpr 2017), 2017: 5987-5995.
- [73] Chen L-C, Papandreou G, Schroff F, et al. Rethinking atrous convolution for semantic image segmentation[J]. arXiv preprint arXiv:1706.05587, 2017.
- [74] Lin J Y, Wang G D, Lau R W H. Progressive Mirror Detection[J]. 2020 Ieee/Cvf Conference on Computer Vision and Pattern Recognition (Cvpr), 2020: 3694-3702.
- [75] Berman M, Triki A R, Blaschko M B. The Lovasz-Softmax loss: A tractable surrogate for the optimization of the intersection-over-union measure in neural networks[J]. 2018 Ieee/Cvf Conference on Computer Vision and Pattern Recognition (Cvpr), 2018: 4413-4421.
- [76] Fang H S, Xie S Q, Tai Y W, et al. RMPE: Regional Multi-Person Pose Estimation[J]. 2017 Ieee International Conference on Computer Vision (Iccv), 2017: 2353-2362.
- [77] Chen Y L, Wang Z C, Peng Y X, et al. Cascaded Pyramid Network for Multi-Person Pose Estimation[J]. 2018 Ieee/Cvf Conference on Computer Vision and Pattern Recognition (Cvpr), 2018: 7103-7112.

-
- [78] Wei S E, Ramakrishna V, Kanade T, et al. Convolutional Pose Machines[J]. 2016 Ieee Conference on Computer Vision and Pattern Recognition (Cvpr), 2016: 4724-4732.
 - [79] Newell A, Yang K U, Deng J. Stacked Hourglass Networks for Human Pose Estimation[J]. Computer Vision - Eccc 2016, Pt Viii, 2016, 9912: 483-499.
 - [80] Cao Z, Simon T, Wei S E, et al. Realtime Multi-Person 2D Pose Estimation using Part Affinity Fields[J]. 30th Ieee Conference on Computer Vision and Pattern Recognition (Cvpr 2017), 2017: 1302-1310.
 - [81] Sun K, Xiao B, Liu D, et al. Deep High-Resolution Representation Learning for Human Pose Estimation[J]. 2019 Ieee/Cvf Conference on Computer Vision and Pattern Recognition (Cvpr 2019), 2019: 5686-5696.
 - [82] Lin T Y, Maire M, Belongie S, et al. Microsoft COCO: Common Objects in Context[J]. Computer Vision - Eccc 2014, Pt V, 2014, 8693: 740-755.
 - [83] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[J]. Medical Image Computing and Computer-Assisted Intervention, Pt Iii, 2015, 9351: 234-241.
 - [84] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2016.
 - [85] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:14091556, 2014.
 - [86] Xia Z, Pan X, Song S, et al. Vision transformer with deformable attention[C]. proceedings of the Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, F, 2022.
 - [87] Paszke A, Gross S, Massa F, et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library[J]. Advances in Neural Information Processing Systems 32 (Nips 2019), 2019, 32.
 - [88] Deng J, Dong W, Socher R, et al. ImageNet: A Large-Scale Hierarchical Image Database[J]. Cvpr: 2009 Ieee Conference on Computer Vision and Pattern Recognition, Vols 1-4, 2009: 248-255.
 - [89] Contributors M. MMSegmentation: OpenMMLab Semantic Segmentation Toolbox and Benchmark [M]. <https://github.com/open-mmlab/mms Segmentation>.
 - [90] Lin J, He Z, Lau R W. Rich context aggregation with reflection prior for glass surface detection[C]. proceedings of the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, F, 2021.
 - [91] Yang X, Mei H, Xu K, et al. Where is my mirror?[C]. proceedings of the Proceedings of the IEEE/CVF International Conference on Computer Vision, F, 2019.

- [92] Tan X, Lin J, Xu K, et al. Mirror detection with the visual chirality cue[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(3): 3492-3504.
- [93] Realitycapture[M/OL]. Epic Games Commerce GmbH, 2022
- [94] Zhang K, Riegler G, Snavely N, et al. Nerf++: Analyzing and improving neural radiance fields[J]. arXiv preprint arXiv:201007492, 2020.
- [95] Guo Y C, Kang D, Bao L C, et al. NeRFReN: Neural Radiance Fields with Reflections[J]. 2022 Ieee/Cvf Conference on Computer Vision and Pattern Recognition (Cvpr 2022), 2022: 18388-18397.

致 谢

首先，我要特别感谢我的导师宋亮。在整个研究生生涯中，宋老师无私地给予我指导和关怀，他悉心的指导和无尽的耐心为我确立了更高的学术追求，每一次讨论和指导都让我受益匪浅。承蒙教诲，心存感激，祝老师平安健康，万事顺利。

我还要感谢我的家人，他们无条件的爱与支持是我最坚实的后盾，让我始终充满勇气挑战困难，克服困难。

此外，我还要感谢我的朋友们，特别是陈启昌同学，在学术上和生活中给予了我大量帮助，我们共同度过的时光将是我永远珍藏的记忆。

最后，我要对所有在我研究生生涯中给予帮助和支持的老师、同学和朋友表达最诚挚的感谢。感恩所有的相遇。

在学期间完成的相关学术成果

学术论文：

- [1] **Niu S**, Tang J, Lin X, et al. Multi-view Coherence for Outdoor Reflective Surfaces[C]. International Conference on Intelligent Computing. Singapore: Springer Nature Singapore, 2023: 593-603.

学位论文答辩委员会名单

主席	苏劲松	厦门大学	教授	博士生导师
委员	赖永炫	厦门大学	教授	硕士生导师
		中国信息通信科		
	匡立伟	技集团(烽火通信科技股份有限公司)	高级工程师	-
秘书	林伟强	厦门大学	-	-

答辩时间：2024 年 5 月 25 日下午

答辩地点：厦门大学信息学院 1 号楼 108 会议